

Fakultät Für Informatik und Mathematik
Stochastic Engineering in Business and Finance

Master-Thesis

Interpretation linearer Modelle mit SHAP

Interpretation of linear models with SHAP

Betreuer: Prof. Dr. Andreas Zielke

Eingereicht von:
Simon Symhoven, 49651418
Boschetsriederstraße 59A, D-81379 München
simon.symhoven@hm.edu

Eingereicht am:
München, den 15. Januar 2024

Abstract

In der vorliegenden Masterarbeit wird die Interpretation linearer Modelle mittels SHAP untersucht, einem Verfahren, das seine Grundlagen in den Shapley-Werten der kooperativen Spieltheorie findet. Die Untersuchung beginnt mit einem Rückblick auf die historische Entwicklung der Shapley-Werte und setzt sich mit einer detaillierten Herleitung sowie einer Analyse der zugrundeliegenden axiomatischen Prinzipien fort. Es wird dargelegt, wie SHAP auf Basis der Shapley-Werte konzipiert wurde, um Beiträge der einzelnen Merkmale zur Vorhersagegenauigkeit eines Modells zu quantifizieren. Die Anwendung des Konzepts auf einen Datensatz aus der Praxis, bearbeitet mit dem Python-Paket **shap**, verdeutlicht die Handhabung und praktische Relevanz des Ansatzes. Den Schlussstein der Arbeit bildet ein Abgleich der gewonnenen Einsichten durch SHAP mit traditionellen Methoden zur Bestimmung der Relevanz von Modellmerkmalen. Zudem wird eine kritische Betrachtung der Grenzen und Herausforderungen, die SHAP mit sich bringt, präsentiert.

Inhaltsverzeichnis

1	Einleitung	1
2	Historischer Kontext und Begriffsdefinitionen	2
2.1	Der Ursprung der Shapley-Werte in der kooperativen Spieltheorie . . .	2
2.2	Shapley-Werte, SHAP, SHAP-Werte und <code>shap</code>	2
3	Theorie der Shapley-Werte	4
3.1	Wie lässt sich der Gewinn gerecht aufteilen?	4
3.2	Formale Definition	7
3.3	Axiomatische Grundlage	8
4	Von Shapley-Werten zu SHAP: Brückenschlag zur Modellinterpretation . .	10
4.1	Berechnung der SHAP-Werte unter Berücksichtigung der zugrundelie- genden Verteilung	12
4.2	Kontextualisierte axiomatische Grundlage der Shapley-Werte	16
5	Komplexitätsbewältigung bei der Berechnung von SHAP-Werten	18
5.1	Approximation der marginalen Beiträge mittels Monte Carlo Integration	19
5.2	Schätzung von Koalitionen	20
5.2.1	Linearer SHAP Estimator für lineare Modelle	20
5.2.2	Schätzung durch Permutationen	21
6	Praktische Anwendung von SHAP auf lineare Modelle	23
6.1	Lineare Modelle als analytische Grundlage	23
6.2	Einführung in das <code>shap</code> Python-Paket	25
6.3	Einführung in den Datensatz	26
6.4	Explorative Datenanalyse & Datenaufbereitung	27
6.5	Modellierung der linearen Regression	29

6.6	Berechnung von SHAP-Werten	30
7	Ergebnisse	33
7.1	Lineares Regressionmodell	33
7.2	Interpretation der Koeffizienten & Permutation Feature Importance . .	34
7.3	Interpretation mit SHAP	37
7.3.1	Lokale Interpretation	37
7.3.2	Globale Interpretation	40
8	Fazit	44
	Literaturverzeichnis	46
	Abbildungsverzeichnis	47
	Tabellenverzeichnis	48
	Quellcodeverzeichnis	49
	Eidesstattliche Erklärung	50
	Anhänge	51
	Anhang A Quellcode	51
	A.1 requirements.txt	51
	A.2 charts.py	51
	A.3 linreg.py	52

1. Einleitung

In einer Ära, in der datengetriebene Entscheidungsfindung und automatisierte Modelle zunehmend an Bedeutung gewinnen, wird die Fähigkeit zur Erklärung und Interpretation dieser Modelle immer wichtiger. Vor diesem Hintergrund gewinnen Shapley-Werte, ein Konzept aus der kooperativen Spieltheorie, zunehmend an Bedeutung in der Welt des maschinellen Lernens [Mol23, S. 3].

In dieser Masterarbeit wird eine tiefgehende Untersuchung der Shapley-Werte vorgenommen, wobei ihr Potenzial für die Interpretation von Machine Learning-Modellen, insbesondere linearen Modellen, und ihre Anwendbarkeit auf reale Datensätze erforscht wird.

Die Arbeit beginnt mit einer ausführlichen Einführung in die Shapley-Werte, indem ihre historischen Ursprünge und ihre Verbindung zur kooperativen Spieltheorie beleuchtet werden. Durch die Analyse relevanter Literatur werden die theoretischen Grundlagen dieser Werte ergründet und ihre Bedeutung für die Interpretation von Modellen hervorgehoben.

Anschließend wird der Fokus auf die Anpassung und Erweiterung der Shapley-Werte für maschinelles Lernen gelegt. Hierbei wird untersucht, wie Shapley-Werte modifiziert werden können, um tiefere Einsichten in die Gewichtung und Bedeutung einzelner Merkmale innerhalb komplexer Machine Learning-Modelle zu liefern. Dabei wird ein Vergleich mit bestehenden Methoden, wie der Permutation Feature Importance, gezogen, um die Einzigartigkeit und den Mehrwert der Shapley-Werte hervorzuheben.

Ein wesentlicher Teil der Arbeit widmet sich der praktischen Anwendung der Shapley-Werte. Durch die Analyse eines realen Datensatzes wird die Methodik in der Praxis angewendet. Dies dient nicht nur dazu, die Wirksamkeit der Shapley-Werte zu demonstrieren, sondern auch, um ihre Aussagekraft und Anwendungsgrenzen in realen Szenarien zu evaluieren. Die Fallstudie zur Vorhersage der Druckfestigkeit von Beton bietet dabei ein konkretes Beispiel, anhand dessen die Nuancen und die Tiefe der durch SHAP ermöglichten Analysen veranschaulicht werden.

Abschließend werden die gewonnenen Erkenntnisse zusammengefasst und reflektiert. Es wird speziell die Rolle und das Potenzial der Shapley-Werte in diesem Kontext beleuchtet. Dabei werden auch die Grenzen und Herausforderungen, die mit der Anwendung von Shapley-Werten verbunden sind, kritisch diskutiert.

2. Historischer Kontext und Begriffsdefinitionen

2.1. Der Ursprung der Shapley-Werte in der kooperativen Spieltheorie

Der Ursprung der Shapley-Werte liegt in der kooperativen Spieltheorie, einem fundamentalen Zweig der Spieltheorie. Dieser Bereich beschäftigt sich mit der Analyse von Situationen, in denen Akteure zusammenarbeiten, um gemeinsame Ziele zu erreichen. Zentrales Anliegen ist dabei die gerechte Verteilung der entstehenden Gewinne unter den Akteuren. Ein Schlüsselkonzept dieser Theorie ist die sogenannte „Charakteristische Funktion“, welche die Bewertung der Gewinnverteilung einer Koalition von Akteuren ermöglicht.

Die Shapley-Werte, entwickelt von Lloyd Shapley in den 1950er Jahren, bieten einen methodischen Ansatz, um den individuellen Beitrag eines jeden Akteurs zur kooperativen Zusammenarbeit gerecht zu bewerten. Dies geschieht durch die Durchschnittsbewertung der Beiträge über sämtliche mögliche Koalitionen hinweg. Diese Methode erweist sich als äußerst nützlich, um eine gerechte und rationale Verteilung von Gewinnen in vielfältigen Szenarien zu ermöglichen, sei es in wirtschaftlichen Verhandlungen oder der Aufteilung von Ressourcen [Mol22, S. 215].

Das Verständnis der kooperativen Spieltheorie und ihrer Anwendung in Form der Shapley-Werte ermöglicht es, dieses theoretische Konzept auf den Bereich des maschinellen Lernens zu übertragen. In dieser Arbeit wird der Übergang von abstrakten Spieltheorie-Konzepten zu konkreten Anwendungen in der Welt der datengetriebenen Modelle erforscht.

Zur Erreichung dieses Ziels werden in den kommenden Abschnitten nicht nur die formalen Definitionen und Eigenschaften der Shapley-Werte erläutert, sondern auch ihre Adaption und Anwendung auf Machine Learning-Modelle in Betracht gezogen. Die Anwendbarkeit wird durch die praktische Anwendung auf einen realen Datensatz verdeutlicht.

2.2. Shapley-Werte, SHAP, SHAP-Werte und shap

Zur Verdeutlichung und Abgrenzung der verschiedenen, jedoch verwandten Begrifflichkeiten, die im Kontext dieser Arbeit Verwendung finden, ist eine kurze Einordnung essenziell.

Beginnend mit den Shapley-Werten, entstammt dieser Begriff der kooperativen Spieltheorie und beschreibt eine Methode, um den fairen Beitrag eines Spielers zu der

Gesamtauszahlung eines kooperativen Spiels zu bestimmen.

SHAP (SHapley Additive exPlanations) ist ein Interpretationsframework, das die Shapley-Werte in den Bereich des maschinellen Lernens überträgt. Der Begriff wurde erstmals von Lundberg und Lee eingeführt [LL17, S. 1].

Die SHAP-Werte sind dann die konkreten quantitativen Beiträge der einzelnen Merkmale zu einer bestimmten Vorhersage, berechnet basierend auf dem SHAP-Framework.

Das Python-Paket **shap** schließlich ist eine Implementierung, die es praktikabel macht, SHAP-Werte in der Anwendung zu berechnen und zu visualisieren. Es stellt eine reiche Auswahl an Werkzeugen zur Verfügung, um diese Werte und ihre Auswirkungen zu interpretieren [Mol23, S. 14].

3. Theorie der Shapley-Werte

In diesem Kapitel werden die Shapley-Werte als Instrument zur gerechten Aufteilung von Gewinnen in kooperativen Spielen vorgestellt. Durch die Verwendung eines praktischen Beispiels – der Aufteilung eines Preisgeldes aus einem Designwettbewerb unter den Gewinnern – wird zunächst eine intuitive Einführung in das Konzept gegeben. Anschließend wird die formale Definition der Shapley-Werte erläutert, um die theoretischen Grundlagen für ihre Berechnung und Anwendung zu legen.

3.1. Wie lässt sich der Gewinn gerecht aufteilen?

Angenommen, drei Teilnehmer, Anna, Ben und Carla, haben als Team kooperiert und den ersten Platz bei einem Designwettbewerb belegt¹. Dieser Erfolg führt zu einem Gesamtgewinn von 1000 €. Das Preisgeld für den zweiten Platz beträgt 750 € und 500 € für den dritten Platz. Die Herausforderung besteht nun darin, den Gewinn auf eine Weise zu verteilen, die den individuellen Beitrag jedes Teilnehmers zur Erzielung des ersten Platzes gerecht widerspiegelt.

Die Situation wird komplizierter, wenn man bedenkt, dass jeder Teilnehmer unterschiedlich zu dem Erfolg beigetragen hat und ihre individuellen Leistungen auch zu verschiedenen Ausgängen geführt hätten, wenn sie alleine oder in anderen Teilkonstellationen angetreten wären.

Um eine faire Aufteilung des Preisgeldes zu erreichen, betrachten wir die hypothetischen Gewinne, die Anna, Ben und Carla erzielt hätten, wenn sie in unterschiedlichen Konstellationen am Wettbewerb teilgenommen hätten. Tabelle 1 zeigt die gegebene Gewinnverteilung der verschiedenen Koalitionen. Die Koalition \emptyset entspricht dabei der leeren Koalition – der Nichtteilnahme an dem Wettbewerb.

Zur Berechnung der Shapley-Werte ist es erforderlich, den marginalen Beitrag jedes Spielers zu erfassen. Marginalbeiträge in der Spieltheorie, und speziell im Kontext der Shapley-Werte, sind die zusätzlichen Beiträge, die ein Spieler (Teilnehmer) zum Gesamtgewinn einer Koalition beiträgt, wenn er dieser beitrifft. Die Berechnung des marginalen Beitrags eines Teilnehmers erfolgt, indem man den Wert der Koalition ohne diesen Teilnehmer vom Wert der Koalition mit dem Teilnehmer subtrahiert [Mol23, S. 18].

In diesem Beispiel mit Anna, Ben und Carla, die an einem Designwettbewerb teil-

¹In Anlehnung an das Beispiel aus Kapitel 4.1 „Who’s going to pay for that taxi?“ [Mol23, S.17-20].

Tabelle 1.: Potenzielle Gewinne für verschiedene Teilnehmerkonstellationen im Designwettbewerb.

Koalition	Gewinn	Bemerkung
\emptyset	0 €	Keine Teilnahme
{Anna}	500 €	3. Platz als Einzelteilnehmerin
{Ben}	750 €	2. Platz als Einzelteilnehmer
{Carla}	0 €	Kein Gewinn als Einzelteilnehmerin
{Anna, Ben}	750 €	2. Platz als Team ohne Carla
{Anna, Carla}	750 €	2. Platz als Team ohne Ben
{Ben, Carla}	500 €	3. Platz als Team ohne Anna
{Anna, Ben, Carla}	1000 €	1. Platz als Gesamtteam

Quelle: Eigene Darstellung.

nehmen, ist der marginale Beitrag von Anna zur Koalition von {Ben} der zusätzliche Wert, den sie einbringt, wenn sie sich Ben anschließt, ausgehend von Bens individuellem Gewinn.

Tabelle 2.: Marginalbeiträge der einzelnen Teilnehmer zu den möglichen Koalitionen.

Teilnehmer	Zur Koalition	Gewinn vorher	Gewinn nachher	Marginalbeitrag
Anna	\emptyset	0 €	500 €	500 €
Anna	{Ben}	750 €	750 €	0 €
Anna	{Carla}	0 €	750 €	750 €
Anna	{Ben, Carla}	500 €	1000 €	500 €
Ben	\emptyset	0 €	750 €	750 €
Ben	{Anna}	500 €	750 €	250 €
Ben	{Carla}	0 €	500 €	500 €
Ben	{Anna, Carla}	750 €	1000 €	250 €
Carla	\emptyset	0 €	0 €	0 €
Carla	{Anna}	500 €	750 €	250 €
Carla	{Ben}	750 €	500 €	-250 €
Carla	{Anna, Ben}	750 €	1000 €	250 €

Quelle: Eigene Darstellung.

Tabelle 2 illustriert den Gewinn jeder möglichen Koalition ohne den betrachteten Spieler und den neuen Gesamtgewinn, sobald dieser Spieler der Koalition beitrifft. Der marginale Beitrag jedes Spielers wird dann als die Differenz zwischen diesen beiden Werten berechnet und gibt Aufschluss über den individuellen Wertbeitrag zum gemeinschaftlichen Erfolg.

Nachdem die marginalen Beiträge jedes Teilnehmers für die verschiedenen Koalitionen festgestellt wurden, ist der nächste Schritt, die Shapley-Werte zu bestimmen, welche eine faire Aufteilung des Gesamtgewinns erlauben. Hierzu wird jede mögliche Permutation betrachtet, in der die Spieler der Koalition beitreten könnten. Jede dieser Permutationen liefert unterschiedliche marginale Beiträge für die Spieler, je nach der Reihenfolge ihres Beitritts, wie 2 zeigt [Mol23, S. 19].

Im Falle dieses Beispiels mit Anna, Ben und Carla bedeutet dies, dass alle möglichen Reihenfolgen berücksichtigt werden müssen, in denen sie zum ersten Platz beigetragen haben könnten. Die Shapley-Werte werden dann als Durchschnitt der marginalen

Beiträge über alle Permutationen berechnet. Dies gewährleistet, dass jeder Spieler einen Anteil des Preisgeldes erhält, der seinem durchschnittlichen Beitrag zum Erfolg entspricht [Mol23, S. 20].

Bei drei Teilnehmern existieren $3! = 3 \cdot 2 \cdot 1 = 6$ Permutationen:

1. Anna, Ben, Carla
2. Anna, Carla, Ben
3. Ben, Anna, Carla
4. Carla, Anna, Ben
5. Ben, Carla, Anna
6. Carla, Ben, Anna

Jede Permutation entspricht einer Koalitionsbildung. Anna wird in zwei Koalitionsbildungen (1. und 2.) einer leeren Koalition hinzugefügt. In weiteren zwei Koalitionsbildungen (5. und 6.) wird Anna der bestehenden Koalition aus Ben und Carla hinzugefügt. In den beiden übrigen Koalitionsbildungen wird Anna einmal der Koalition bestehend aus Ben (3.) und einmal der Koalition bestehend aus Carla (4.) hinzugefügt.

Zusammen mit Tabelle 2 lässt sich nun der Shapley-Wert mit den gewichteten durchschnittlichen marginalen Beiträgen für Anna berechnen:

$$\frac{1}{6} \left(\underbrace{2 \cdot 500\text{€}}_{A \rightarrow \{\emptyset\}} + \underbrace{1 \cdot 0\text{€}}_{A \rightarrow \{B\}} + \underbrace{1 \cdot 750\text{€}}_{A \rightarrow \{C\}} + \underbrace{2 \cdot 500\text{€}}_{A \rightarrow \{B, C\}} \right) \approx 458,34\text{€}. \quad (3.1)$$

Analog gilt dies für Ben:

$$\frac{1}{6} \left(\underbrace{2 \cdot 750\text{€}}_{B \rightarrow \{\emptyset\}} + \underbrace{1 \cdot 250\text{€}}_{B \rightarrow \{A\}} + \underbrace{1 \cdot 500\text{€}}_{B \rightarrow \{C\}} + \underbrace{2 \cdot 250\text{€}}_{B \rightarrow \{A, C\}} \right) \approx 458,34\text{€}, \quad (3.2)$$

und Carla:

$$\frac{1}{6} \left(\underbrace{2 \cdot 0\text{€}}_{C \rightarrow \{\emptyset\}} + \underbrace{1 \cdot 250\text{€}}_{C \rightarrow \{A\}} + \underbrace{1 \cdot (-250\text{€})}_{C \rightarrow \{B\}} + \underbrace{2 \cdot 250\text{€}}_{C \rightarrow \{A, B\}} \right) \approx 83,34\text{€} \quad (3.3)$$

Auf Basis der gewichteten durchschnittlichen marginalen Beiträge lässt sich feststellen, dass Anna und Ben jeweils einen Shapley-Wert von ungefähr 458,34 € erhalten, während Carla einen Shapley-Wert von etwa 83,34 € zugewiesen bekommt. Diese Werte spiegeln den fairen Anteil jedes Teilnehmers an der Gesamtprämie wider, basierend auf ihrem individuellen Beitrag zum Erfolg des Teams [Mol23, S. 20]. Mit dieser konkreten Anwendung der Shapley-Werte auf ein alltagsnahes Beispiel wird nun die zugrunde liegende Theorie und die formale Definition der Shapley-Werte, die diese Berechnungen ermöglichen, detaillierter betrachtet.

3.2. Formale Definition

Sei $\mathcal{N} = \{1, \dots, n\}$ eine endliche Spielermenge mit $n := |\mathcal{N}|$ Elementen. Sei v die Koalitionsfunktion, die jeder Teilmenge von \mathcal{N} eine reelle Zahl zuweist und insbesondere der leeren Koalition den Wert 0 gibt.

$$\begin{aligned} v &: \mathcal{P}(\mathcal{N}) \longrightarrow \mathbb{R} \\ &: v(\emptyset) \mapsto 0 \end{aligned}$$

Eine nicht leere Teilmenge der Spieler $\mathcal{S} \subseteq \mathcal{N}$ heißt Koalition. \mathcal{N} selbst bezeichnet die große Koalition. Den Ausdruck $v(\mathcal{S})$ nennt man den Wert der Koalition \mathcal{S} . Der Shapley-Wert ordnet nun jedem Spieler aus \mathcal{N} eine Auszahlung für das Spiel v zu.

Der marginale Beitrag eines Spieler $i \in \mathcal{N}$, also der Wertbeitrag eines Spielers zu einer Koalition $\mathcal{S} \subseteq \mathcal{N}$, durch seinen Beitritt, ist

$$v(\mathcal{S} \cup \{i\}) - v(\mathcal{S}). \quad (3.4)$$

Sei $i = \text{Anna}$ und $\mathcal{S} = \{\text{Ben}\}$, dann ist $v(\{\text{Ben}\} \cup \{\text{Anna}\}) - v(\{\text{Ben}\})$ das zusätzliche Preisgeld, welches gewonnen wird, wenn Anna der Koalition mit Ben beitrifft.

Der Shapley-Wert eines Spielers i errechnet sich als das gewichtete Mittel der marginalen Beiträge zu allen möglichen Koalitionen:

$$\varphi_i(\mathcal{N}, v) = \sum_{\mathcal{S} \subseteq \mathcal{N} \setminus \{i\}} \underbrace{\frac{|\mathcal{S}|! \cdot (n-1-|\mathcal{S}|)!}{n!}}_{\text{Gewicht}} \underbrace{v(\mathcal{S} \cup \{i\}) - v(\mathcal{S})}_{\text{marginaler Beitrag von Spieler } i \text{ zur Koalition } \mathcal{S}}. \quad (3.5)$$

Die Summationsnotation $\sum_{\mathcal{S} \subseteq \mathcal{N} \setminus \{i\}}$ erfasst die marginalen Beiträge, die der Spieler i zu allen Koalitionen leistet, die diesen noch nicht einschließen. Die Verwendung von $\mathcal{N} \setminus \{i\}$ stellt sicher, dass Spieler i nur für jene Koalitionen berücksichtigt wird, zu denen er noch beitragen kann. Im Falle von Anna etwa, beziehen sich die Berechnungen auf die Koalitionen bestehend aus der leeren Koalition \emptyset , aus $\{\text{Ben}\}$, $\{\text{Carla}\}$, oder beiden zusammen $\{\text{Ben}, \text{Carla}\}$ (vgl. Berechnung 3.1).

Die Formel $\frac{|\mathcal{S}|! \cdot (n-1-|\mathcal{S}|)!}{n!}$ in der Shapley-Wert-Berechnung reflektiert den Gewichtungsfaktor für die marginalen Beiträge eines Spielers. Hierbei gibt $|\mathcal{S}|!$ die Permutationen der Spieler innerhalb der Koalition \mathcal{S} an, während $(n-1-|\mathcal{S}|)!$ die Anordnungen der außenstehenden Spieler repräsentiert, nachdem der betrachtete Spieler beigetreten ist. Der Bruchteil $\frac{1}{n!}$ normalisiert diesen Wert über alle möglichen Koalitionszusammensetzungen, wodurch die Wahrscheinlichkeit der Bildung einer spezifischen Koalition ausgedrückt wird.

Betrachten wir Anna als den Spieler i und die Koalition $\mathcal{S} = \{\text{Ben}, \text{Carla}\}$. Die

Formel $\frac{|\mathcal{S}|! \cdot (n-1-|\mathcal{S}|)!}{n!}$ berechnet den Gewichtungsfaktor für Annas marginalen Beitrag zur Koalition \mathcal{S} . In diesem Fall ist $|\mathcal{S}| = 2$ und $n = 3$. Somit ergibt sich $|\mathcal{S}|! = 2!$ und $n - 1 - |\mathcal{S}| = 0!$, da nach dem Beitritt von Anna keine weiteren Spieler übrig sind. Der Normalisierungsfaktor ist $n! = 3! = 6$. Daraus folgt:

$$\frac{2! \cdot 0!}{3!} = \frac{2 \cdot 1}{6} = \frac{1}{3}. \quad (3.6)$$

Dies bedeutet, dass unter allen möglichen Permutationen der Spielerreihenfolge, Annas Beitritt zu der Koalition {Ben, Carla} genau ein Drittel der Zeit am Ende geschieht. Somit wird ihr marginaler Beitrag mit diesem Faktor gewichtet, um den Shapley-Wert zu berechnen (vgl. Berechnung 3.1) [Mol23, S. 21f].

3.3. Axiomatische Grundlage

Nachdem die Berechnung des Shapley-Werts für das Beispiel konkretisiert wurde, ist es nun von Bedeutung, die zugrundeliegenden Axiome zu betrachten, welche die theoretische Rechtfertigung für die Methode liefern. Der Shapley-Wert wird nicht nur durch seine Berechnungsmethode, sondern auch durch eine Reihe von Axiomen charakterisiert, die seine Fairness und Kohärenz im Kontext kooperativer Spiele sicherstellen. Lloyd Shapley leitete den Shapley-Wert ursprünglich aus diesen Axiomen ab und bewies, dass dieser der einzige ist, der den Axiomen genügt². Diese Axiome sind wesentliche Bestandteile, die die Einzigartigkeit und die wünschenswerten Eigenschaften des Shapley-Werts als Lösungskonzept definieren [Mol23, S. 22].

Effizienz Der Wert der großen Koalition wird an die Spieler verteilt:

$$\sum_{i \in \mathcal{N}} \varphi_i(\mathcal{N}, v) = v(\mathcal{N}). \quad (3.7)$$

Dies bedeutet, dass die Summe der Shapley-Werte aller Spieler dem Gesamtwert entspricht, den die Koalition aller Spieler zusammen erreichen kann. Der Gesamtwert, den die große Koalition \mathcal{N} , bestehend aus Anna, Ben und Carla, generiert, wird komplett unter den Spielern aufgeteilt [Mol23, S. 22]. Unter Vernachlässigung minimaler Rundungsdifferenzen entspricht die Summe der Shapley-Werte, berechnet in den Gleichungen 3.1, 3.2 und 3.3, dem kollektiven Ertrag der großen Koalition:

$$458,34\text{€} + 458,34\text{€} + 83,32\text{€} \approx 1000\text{€} \quad (3.8)$$

²Eine detaillierte Darstellung dieser Axiome und des Beweises ihrer Einzigartigkeit findet sich in Shapleys Originalarbeit, deren umfassende Behandlung jedoch den Rahmen dieser Arbeit überschreiten würde [Sha53, S. 307-318].

Symmetrie Zwei Spieler i und j , die die gleichen marginalen Beiträgen zu jeder Koalition haben erhalten das Gleiche:

$$v(\mathcal{S} \cup \{i\}) = v(\mathcal{S} \cup \{j\}), \forall \mathcal{S} \subseteq \mathcal{N} \setminus \{i, j\} \Rightarrow \varphi_i(\mathcal{N}, v) = \varphi_j(\mathcal{N}, v). \quad (3.9)$$

Obwohl Anna und Ben den gleichen Shapley-Wert erhalten, ist dies nicht auf das Symmetrieaxiom zurückzuführen, da ihre marginalen Beiträge zu den Koalitionen variieren. Zum Beispiel leistet Anna keinen Beitrag zur Koalition, wenn Ben bereits Teil davon ist, während Ben einen positiven Beitrag leistet, wenn Anna bereits zur Koalition gehört (vgl. Tabelle 2). Dies zeigt, dass die Gleichheit ihrer Shapley-Werte ein Ergebnis der spezifischen Zahlenkonstellation in diesem Szenario ist und nicht aus der symmetrischen Interaktion zwischen den beiden Spielern resultiert.

Null-Spieler-Eigenschaft (Dummy-Spieler-Eigenschaft) Ein Spieler i der zu jeder Koalition nichts beiträgt erhält den Wert Null:

$$v(\mathcal{S} \cup \{i\}) = v(\mathcal{S}), \forall \mathcal{S} \subseteq \mathcal{N} \setminus \{i\} \Rightarrow \varphi_i(\mathcal{N}, v) = 0. \quad (3.10)$$

Dies stellt sicher, dass ein Spieler, der keinen Beitrag leistet, auch nicht belohnt wird.

Additivität Wenn das Spiel in zwei unabhängige Spiele mit Koalitionsfunktionen v und w zerlegt werden kann, dann ist die Auszahlung jedes Spielers im zusammengesetzten Spiel die Summe der Auszahlungen in den aufgeteilten Spielen:

$$\varphi_i(\mathcal{N}, v + w) = \varphi_i(\mathcal{N}, v) + \varphi_i(\mathcal{N}, w). \quad (3.11)$$

Wenn Anna, Ben und Carla neben dem ersten Wettbewerb an einem zweiten, unabhängigen Wettbewerb teilnehmen, besagt das Additivitätsaxiom, dass die Shapley-Werte jedes Spielers aus beiden Wettbewerben einfach die Summe ihrer individuellen Shapley-Werte aus jedem einzelnen Wettbewerb sind. Dies impliziert, dass die faire Aufteilung der Gewinne aus beiden Wettbewerben konsistent bleibt, indem die aus dem ersten Wettbewerb abgeleiteten Prinzipien auf den zweiten Wettbewerb übertragen und dann addiert werden [RWB⁺22, Mol22, S. 5573, S.22f].

4. Von Shapley-Werten zu SHAP: Brückenschlag zur Modellinterpretation

Im Rahmen der kooperativen Spieltheorie ermöglichen die Shapley-Werte eine faire Verteilung des kollektiv erwirtschafteten Nutzens auf die beteiligten Akteure. Diese Methodik findet eine analoge Anwendung in der Welt des maschinellen Lernens, um die Beiträge einzelner Merkmale zur Vorhersageleistung eines Modells zu bewerten [Mol23, S. 26]. Hier wird die Terminologie der Shapley-Werte in den Kontext von Machine Learning Modellen übertragen, wobei jedes Merkmal als „Spieler“ betrachtet wird, dessen Beitrag zur „Auszahlung“ – der Vorhersage des Modells – evaluiert werden soll.

Tabelle 3.: Terminologie der originären Shapley-Werte im Kontext des maschinellen Lernens.

Terminologie Konzept	Terminologie Machine Learning	Ausdruck
Spieler	Merkmal	j
Anzahl aller Spieler	Anzahl aller Merkmale	p
Große Koalition	Menge aller Merkmale	$\mathcal{N} = \{1, \dots, p\}$
Koalition	Menge von Merkmalen	$\mathcal{S} \subseteq \mathcal{N}$
Größe der Koalition	Anzahl der Merkmale in der Koalition \mathcal{S}	$ \mathcal{S} $
Spieler, die nicht in der Koalition sind	Merkmale, die nicht in der Koalition enthalten sind	$C : C = \mathcal{N} \setminus \mathcal{S}$
Koalitionsfunktion	Vorhersage für Merkmalswerte in der Koalition \mathcal{S} abzüglich der Vorhersage im Mittel	$v_{f,x^{(i)}}(\mathcal{S})$
Auszahlung	Vorhersage für eine Beobachtung $x^{(i)}$ abzüglich der Vorhersage im Mittel	$f(x^{(i)}) - \mathbb{E}(f(X))$
Shapley-Wert	Beitrag des Merkmals j zur Auszahlung des Modells für eine Beobachtung $x^{(i)}$	$\varphi_j^{(i)}(\mathcal{N}, f)$

Quelle: [Mol23, S. 26].

Die Koalitionsfunktion $v_{f,x^{(i)}}(\mathcal{S})$ für ein gegebenes Model f und eine Beobachtung $x^{(i)}$ ist definiert als:

$$v_{f,x^{(i)}}(\mathcal{S}) = \int_{\mathbb{R}} f(x_{\mathcal{S}}^{(i)} \cup X_C) d\mathbb{P}_{X_C} - \mathbb{E}(f(X)) \quad (4.1)$$

Diese Funktion berechnet den erwarteten Wert der Vorhersage des Modells f , wenn nur eine Teilmenge \mathcal{S} der Merkmale genutzt wird, um die Vorhersage für die spezifi-

sche Beobachtung $x^{(i)} \in \mathbb{R}^p$ zu treffen. Das Integral $\int_{\mathbb{R}}$ repräsentiert die Berechnung dieses erwarteten Wertes über alle möglichen Werte der Merkmale, die nicht in \mathcal{S} enthalten sind (X_C), gewichtet durch deren Wahrscheinlichkeitsverteilung \mathbb{P}_{X_C} . Die Differenz zum Erwartungswert der Vorhersagen über alle Merkmale $\mathbb{E}(f(X))$ zeigt, wie viel die spezifische Menge an Merkmalen \mathcal{S} zur Vorhersage beiträgt [Mol22, Mol23, S. 221, S. 27].

Der marginale Beitrag eines Merkmals j zu einer Koalition \mathcal{S} ist dann:

$$\begin{aligned} v_{f,x^{(i)}}(\mathcal{S} \cup \{j\}) - v_{f,x^{(i)}}(\mathcal{S}) &= \int_{\mathbb{R}} f(x_{\mathcal{S} \cup \{j\}}^{(i)} \cup X_{C \setminus \{j\}}) d\mathbb{P}_{X_{C \setminus \{j\}}} - \mathbb{E}(f(X)) \quad (4.2) \\ &\quad - \left(\int_{\mathbb{R}} f(x_{\mathcal{S}}^{(i)} \cup X_C) d\mathbb{P}_{X_C} - \mathbb{E}(f(X)) \right) \\ &= \int_{\mathbb{R}} f(x_{\mathcal{S} \cup \{j\}}^{(i)} \cup X_{C \setminus \{j\}}) d\mathbb{P}_{X_{C \setminus \{j\}}} \\ &\quad - \int_{\mathbb{R}} f(x_{\mathcal{S}}^{(i)} \cup X_C) d\mathbb{P}_{X_C} \end{aligned}$$

Diese Gleichung beschreibt, wie sich der erwartete Wert der Vorhersage ändert, wenn das Merkmal j zu der Menge der Merkmale \mathcal{S} hinzugefügt wird [Mol23, S. 29].

Der Beitrag $\varphi_j^{(i)}(\mathcal{N}, f)$ eines Merkmals j für eine Beobachtung $x^{(i)} \in \mathbb{R}^p$ für die Vorhersage $f(x^{(i)})$ ist gegeben als:

$$\begin{aligned} \varphi_j^{(i)}(\mathcal{N}, f) &= \sum_{\mathcal{S} \subseteq \mathcal{N} \setminus \{j\}} \frac{|\mathcal{S}|! \cdot (p - 1 - |\mathcal{S}|)!}{p!} \quad (4.3) \\ &\quad \cdot \left(\int_{\mathbb{R}} f(x_{\mathcal{S} \cup \{j\}}^{(i)} \cup X_{C \setminus \{j\}}) d\mathbb{P}_{X_{C \setminus \{j\}}} - \int_{\mathbb{R}} f(x_{\mathcal{S}}^{(i)} \cup X_C) d\mathbb{P}_{X_C} \right) \end{aligned}$$

Diese Formel ist die zentrale Berechnung der SHAP-Werte im maschinellen Lernen. Sie summiert den gewichteten, marginalen Beitrag des Merkmals j über alle möglichen Kombinationen der anderen Merkmale. Die Gewichtung berücksichtigt die Anzahl der Merkmale in der Koalition \mathcal{S} und die Anzahl der verbleibenden Merkmale, die noch hinzugefügt werden können. Dies ergibt den durchschnittlichen Beitrag des Merkmals j zur Vorhersage für die Beobachtung $x^{(i)}$ [Mol23, S. 29, 30].

Die Integration in der SHAP-Formel ist ein zentraler Schritt, um den erwarteten Beitrag jedes Merkmals unter Berücksichtigung der gesamten Verteilung der Daten zu ermitteln. In diesem Ansatz werden die Merkmale als Zufallsvariablen behandelt, und die Integration erfolgt über die Wahrscheinlichkeitsverteilungen dieser Zufallsvariablen. Durch das Berechnen der erwarteten Vorhersagewerte mit und ohne des jeweiligen Merkmals, unter Einbeziehung der Verteilung aller anderen Merkmale, ermöglicht SHAP eine präzise und umfassende Einschätzung des Einflusses jedes ein-

zernen Merkmals. Dieser Prozess der Marginalisierung, bei dem man über die Wahrscheinlichkeitsverteilungen der Merkmale integriert, erlaubt es, den Beitrag eines jeden Merkmals zu isolieren und unabhängig von der spezifischen Zusammensetzung der anderen Merkmale zu bewerten. Dies führt zu einer fairen und ganzheitlichen Bewertung der Beiträge aller Merkmale zur Vorhersage des Modells [Mol23, S. 28].

4.1. Berechnung der SHAP-Werte unter Berücksichtigung der zugrundeliegenden Verteilung

Ein einfaches Beispiel soll helfen, die Anwendung von SHAP-Werten im Kontext des maschinellen Lernens zu illustrieren¹. Betrachtet wird ein fiktiver Immobilien-Datensatz mit drei Merkmalen: Größe des Hauses in Quadratmetern (x_1), Anzahl der Zimmer (x_2) und Entfernung zum Stadtzentrum in Kilometern (x_3). Es gibt zwei Beobachtungen in diesem Datensatz:

Tabelle 4.: Merkmale von Beobachtungen in einem Immobilien-Datensatz.

	x_1 : Größe (in m^2)	x_2 : Anzahl Zimmer	x_3 : Entfernung zum Zentrum (in km)
$x^{(1)}$	100	3	5
$x^{(2)}$	150	4	10

Quelle: Eigene Darstellung.

Angenommen das Modell $f(x^{(i)})$ prognostiziert den Preis eines Hauses in Euro als eine lineare Kombination der Merkmale:

$$f(x^{(i)}) = 5x_1^{(i)} + 20x_2^{(i)} - 2x_3^{(i)}. \quad (4.4)$$

Die Vorhersagen für die beiden Beobachtungen lauten dann:

$$\begin{aligned} f(x^{(1)}) &= 5x_1^{(1)} + 20x_2^{(1)} - 2x_3^{(1)} \\ &= 5 \cdot 100 + 20 \cdot 3 - 2 \cdot 5 \\ &= 550 \text{ €} \end{aligned} \quad (4.5)$$

und

$$\begin{aligned} f(x^{(2)}) &= 5x_1^{(2)} + 20x_2^{(2)} - 2x_3^{(2)} \\ &= 5 \cdot 150 + 20 \cdot 4 - 2 \cdot 10 \\ &= 810 \text{ €}. \end{aligned} \quad (4.6)$$

¹In Anlehnung an das Beispiel aus Kapitel 8.5.1 „General Idea“ [Mol22, S.215f].

Die erwartete Auszahlung des Modells $\mathbb{E}(f(X))$ wird berechnet als:

$$\begin{aligned}\mathbb{E}(f(X)) &= 5 \cdot \mathbb{E}(X_1) + 20 \cdot \mathbb{E}(X_2) - 2 \cdot \mathbb{E}(X_3) \\ &= 5 \cdot 125 + 20 \cdot 3,5 - 2 \cdot 7,5 \\ &= 680 \text{ €},\end{aligned}\tag{4.7}$$

mit

$$\mathbb{E}(X_j) = \frac{1}{n} \sum_{i=1}^n x_j^{(i)}.\tag{4.8}$$

Sei $\mathcal{N} = \{1, 2, 3\}$ die Menge aller Merkmale und die Beobachtung $x^{(1)} = [100, 3, 5]$. Der SHAP-Wert für jedes Merkmal $j \in \mathcal{N}$ wird unter Berücksichtigung der Verteilung der Daten und der Formel 4.3 berechnet:

$$\begin{aligned}\varphi_j^{(1)}(\mathcal{N}, f) &= \sum_{\mathcal{S} \subseteq \mathcal{N} \setminus \{j\}} \frac{|\mathcal{S}|! \cdot (p - 1 - |\mathcal{S}|)!}{p!} \\ &\quad \cdot \left(\int_{\mathbb{R}} f(x_{\mathcal{S} \cup \{j\}}^{(1)} \cup X_{C \setminus \{j\}}) d\mathbb{P}_{X_{C \setminus \{j\}}} - \int_{\mathbb{R}} f(x_{\mathcal{S}}^{(1)} \cup X_C) d\mathbb{P}_{X_C} \right)\end{aligned}\tag{4.9}$$

wobei $p = |\mathcal{N}| = 3$ die Anzahl der Merkmale ist und X_C die Menge der Merkmale außerhalb der Koalition \mathcal{S} repräsentiert. Die Integrale repräsentieren die erwartete Vorhersage des Modells über die Verteilung der nicht in der Koalition enthaltenen Merkmale.

In linearen Modellen, unter der Prämisse, dass die Merkmale unabhängig voneinander und identisch verteilt sind, ist es möglich, die Berechnung der SHAP-Werte zu vereinfachen. Anstelle der komplexen Integration über die Verteilungen aller Merkmale, kann der Fokus auf die Unterschiede in den Modellvorhersagen gelegt werden, die sich aus dem Hinzufügen oder Entfernen einzelner Merkmale ergeben. Hierbei wird anstelle der spezifischen Werte der nicht in der betrachteten Koalition enthaltenen Merkmale die Erwartungswerte herangezogen. Diese Vereinfachung ermöglicht es, den Einfluss jedes Merkmals auf die Modellvorhersage auf eine direktere und rechnerisch weniger aufwendige Weise zu erfassen. Diese Vereinfachung ist für lineare Modelle angemessen, da die Auswirkungen jedes Merkmals auf die Vorhersage des Modells additiv und unabhängig sind [Mol23, S. 48]. Bei komplexeren, nichtlinearen Modellen ist eine detailliertere Berechnung erforderlich, die oft auf numerischen Methoden oder Annäherungen basiert, mehr dazu in Kapitel 5.

Der Beitrag durch das Hinzufügen des Merkmals x_1 zur bestehenden Koalition $\mathcal{S} = \{x_2\}$ wird nach Formel 4.9 berechnet als:

$$\begin{aligned} \varphi_1^{(1)}(\{x_2\}, f) &= \frac{1! \cdot (3 - 1 - 1)!}{3!} \\ &\cdot \int f(x_1, x_2, X_3) d\mathbb{P}(X_3) - \int f(X_1, x_2, X_3) d\mathbb{P}(X_1, X_3) \end{aligned} \quad (4.10)$$

Da X_1 und X_3 unabhängig und identisch verteilt sind, können X_2 und X_3 durch ihre Erwartungswerte (Gleichung 4.8) ersetzt werden:

$$\begin{aligned} \varphi_1^{(1)}(\{x_2\}, f) &= \frac{1}{6} \left(f(x_1, x_2, \mathbb{E}(X_3)) - f(\mathbb{E}(X_1), x_2, \mathbb{E}(X_3)) \right) \\ &= \frac{1}{6} \left(f(100, 3, 7.5) - f(125, 3, 7.5) \right) \\ &= \frac{1}{6} \left((5 \cdot 100 + 20 \cdot 3 - 2 \cdot 7, 5) - (5 \cdot 125 + 20 \cdot 3 - 2 \cdot 7, 5) \right) \\ &= \frac{1}{6} (545 - 670) \\ &= \frac{1}{6} (-125) \end{aligned} \quad (4.11)$$

Die in Tabelle 5 dargestellten Kombinationen illustrieren die marginalen Beiträge und SHAP-Werte für jedes Merkmal in jeder möglichen Koalition von Merkmalen, bezogen auf die Beobachtung $x^{(1)}$.

Tabelle 5.: Marginalbeiträge der einzelnen Merkmale zu den möglichen Koalitionen für die Beobachtung $x^{(1)}$.

x_j	\mathcal{S}	$v_{f,x^{(1)}}(\mathcal{S})$	$v_{f,x^{(1)}}(\mathcal{S} \cup \{j\})$	$v_{f,x^{(1)}}(\mathcal{S} \cup \{j\}) - v_{f,x^{(1)}}(\mathcal{S})$	Gewicht	$\varphi_j^{(1)}(\mathcal{S}, f)$
x_1	\emptyset	680	555	-125	$\frac{1}{3}$	-41,67
x_1	$\{x_2\}$	670	545	-125	$\frac{1}{6}$	-20,83
x_1	$\{x_3\}$	685	560	-125	$\frac{1}{6}$	-20,83
x_1	$\{x_2, x_3\}$	675	550	-125	$\frac{1}{3}$	-41,67
x_2	\emptyset	680	670	-10	$\frac{1}{3}$	-3,33
x_2	$\{x_1\}$	555	545	-10	$\frac{1}{6}$	-1,67
x_2	$\{x_3\}$	685	675	-10	$\frac{1}{6}$	-1,67
x_2	$\{x_1, x_3\}$	560	550	-10	$\frac{1}{3}$	-3,33
x_3	\emptyset	680	685	5	$\frac{1}{3}$	1,67
x_3	$\{x_1\}$	555	560	5	$\frac{1}{6}$	0,83
x_3	$\{x_2\}$	670	675	5	$\frac{1}{6}$	0,83
x_3	$\{x_1, x_2\}$	545	550	5	$\frac{1}{3}$	1,67

Quelle: Eigene Darstellung.

Diese Analyse ist ebenso auf die Beobachtung $x^{(2)}$ anwendbar und erfordert eine analoge Vorgehensweise, wie in Tabelle 6 dargestellt:


Die in den Tabellen 5 und 6 dargestellten SHAP-Werte für die Beobachtungen $x^{(1)}$ und $x^{(2)}$ zeigen eine interessante Symmetrie. Für jedes Merkmal entspricht der SHAP-Wert für $x^{(2)}$ genau dem negativen Wert für $x^{(1)}$. Die beobachtete Inversion der SHAP-Werte zwischen den Beobachtungen $x^{(1)}$ und $x^{(2)}$ lässt sich durch die zen-

Tabelle 6.: Marginalbeiträge der einzelnen Merkmale zu den möglichen Koalitionen für die Beobachtung $x^{(2)}$.

x_j	\mathcal{S}	$v_{f,x^{(2)}}(\mathcal{S})$	$v_{f,x^{(2)}}(\mathcal{S} \cup \{j\})$	$v_{f,x^{(2)}}(\mathcal{S} \cup \{j\}) - v_{f,x^{(2)}}(\mathcal{S})$	Gewicht	$\varphi_j^{(2)}(\mathcal{S}, f)$
x_1	\emptyset	680	805	125	$\frac{1}{3}$	41,67
x_1	$\{x_2\}$	690	815	125	$\frac{1}{6}$	20,83
x_1	$\{x_3\}$	675	800	125	$\frac{1}{6}$	20,83
x_1	$\{x_2, x_3\}$	685	810	125	$\frac{1}{3}$	41,67
x_2	\emptyset	680	690	10	$\frac{1}{3}$	3,33
x_2	$\{x_1\}$	805	815	10	$\frac{1}{6}$	1,67
x_2	$\{x_3\}$	675	685	10	$\frac{1}{6}$	1,67
x_2	$\{x_1, x_3\}$	800	810	10	$\frac{1}{3}$	3,33
x_3	\emptyset	680	675	-5	$\frac{1}{3}$	-1,67
x_3	$\{x_1\}$	805	800	-5	$\frac{1}{6}$	-0,83
x_3	$\{x_2\}$	690	685	-5	$\frac{1}{6}$	-0,83
x_3	$\{x_1, x_2\}$	815	810	-5	$\frac{1}{3}$	-1,67


Quelle: Eigene Darstellung.

trale Rolle des Erwartungswerts des Modells erklären. Das Modell prognostiziert im Mittel einen Immobilienpreis von 680 €. In einem Szenario, in dem nur zwei Beobachtungen vorhanden sind, spiegeln die Beobachtungen $x^{(1)}$ und $x^{(2)}$ entgegengesetzte Abweichungen vom Erwartungswert wider. Die SHAP-Werte, die den Beitrag jedes Merkmals zur Abweichung der Vorhersage vom Mittelwert messen, zeigen daher für $x^{(1)}$ und $x^{(2)}$ genau entgegengesetzte Werte. Dieses Phänomen resultiert aus der Tatsache, dass die Merkmalsbeiträge in Bezug auf den Erwartungswert berechnet werden und unsere beispielhaften Beobachtungen symmetrisch um diesen Mittelwert verteilt sind. Folglich heben sich ihre Beiträge im Kontext unseres linearen Modells exakt auf, was die Konsistenz und Zuverlässigkeit der SHAP-Wert-Berechnung unterstreicht.

Abbildung 1.: Beitrag der Merkmale $x_{j \in \{1,2,3\}}$ zur Modellvorhersage $f(x^{(1)})$.

Quelle: Eigene Darstellung, A.2.

Das Modell $f(x^{(i)})$ prognostiziert im Mittel einen Immobilienpreis von 680 €. Im Vergleich zur Verteilung des jeweiligen Merkmals, reduziert die Größe der Wohnung ($x_1^{(1)}$) und die Anzahl der Zimmer ($x_2^{(1)}$) die Prognose des Preises für die Immobilie $x^{(1)}$ um insgesamt 135 €, während die Entfernung zum Stadtzentrum ($x_3^{(1)}$) den Preis der Wohnung um 5 € erhöht, wie in Abbildung 1 veranschaulicht. Abbildung 2 visualisiert die SHAP-Werte für die Immobilie $x^{(2)}$:

Abbildung 2.: Beitrag der Merkmale $x_{j \in \{1,2,3\}}$ zur Modellvorhersage $f(x^{(2)})$.

Quelle: Eigene Darstellung, A.2.

4.2. Kontextualisierte axiomatische Grundlage der Shapley-Werte

Die in Tabellen 5 und 6 präsentierten Ergebnisse bieten eine Grundlage, um die Konformität der SHAP-Werte mit den etablierten Axiomen der Shapley-Werte, wie sie im Kapitel 3.3 diskutiert wurden, zu beurteilen. Die Axiome der SHAP-Werte stellen eine adaptierte und kontextualisierte Anwendung dieser Prinzipien auf die Interpretation von Modellvorhersagen dar [AFSS19, S. 16f].

Effizienz Das Effizienzaxiom besagt, dass die Summe der SHAP-Werte aller Merkmale für eine gegebene Beobachtung $x^{(i)}$ gleich der Differenz zwischen der Modellvorhersage für diese Beobachtung $f(x^{(i)})$ und der durchschnittlichen Modellvorhersage $\mathbb{E}(f(X))$ sein muss:

$$\sum_{j=1}^p \varphi_j^{(i)}(\mathcal{N}, f) = f(x^{(i)}) - \mathbb{E}(f(X)), \quad (4.12)$$

[Mol22, S. 221]. Für die Beobachtung $x^{(1)}$ aus Kapitel 4.1 und den Berechnungen für $f(x^{(1)})$ (Gleichung 4.5), sowie $\mathbb{E}(f(X))$ (Gleichung 4.7) ergibt sich:

$$\begin{aligned} \sum_{j=1}^3 \varphi_j^{(1)}(\mathcal{N}, f) &= -130 \\ f(x^{(1)}) - \mathbb{E}(f(X)) &= 550 - 680 = -130, \end{aligned} \quad (4.13)$$

womit das Effizienzaxiom erfüllt ist. Die Differenz der Vorhersage einer konkreten Beobachtung zur durchschnittlichen Modellvorhersage wird auf alle Merkmale verteilt.

Symmetrie Das Symmetrieaxiom fordert, dass zwei Merkmale i und j , die in jeder Koalition denselben Beitrag leisten, auch denselben SHAP-Wert erhalten müssen.

In dem hier betrachteten Fall der Immobilienpreisprognose würde dies bedeuten, dass wenn zwei Merkmale, beispielsweise die Größe einer Wohnung und die Anzahl der Zimmer, immer den gleichen Einfluss auf den Preis hätten, unabhängig von der Kombination anderer Merkmale, ihre SHAP-Werte identisch sein müssen:

$$v(\mathcal{S} \cup \{i\}) = v(\mathcal{S} \cup \{j\}), \forall \mathcal{S} \subseteq \mathcal{N} \setminus \{i, j\} \Rightarrow \varphi_i(\mathcal{N}, v) = \varphi_j(\mathcal{N}, v), \quad (4.14)$$

[Mol22, S. 221]. Dies wird durch die Tabellen 5 und 6 nicht illustriert, da jedes Merkmal einen unterschiedlichen Beitrag liefert, was die Anwendung dieses Axioms in diesem speziellen Fall ausschließt.

Null-Spieler-Eigenschaft (Dummy-Spieler-Eigenschaft) Ein Merkmal i , das keinen Einfluss auf die Modellvorhersage hat, erhält gemäß der Null-Spieler-Eigenschaft einen SHAP-Wert von Null. Im Kontext des Beispiels würde ein Merkmal, das keine Veränderung in der Vorhersage bewirkt, unabhängig von den anderen Merkmalen, einen SHAP-Wert von Null erhalten:

$$v(\mathcal{S} \cup \{i\}) = v(\mathcal{S}), \forall \mathcal{S} \subseteq \mathcal{N} \setminus \{i\} \Rightarrow \varphi_i(\mathcal{N}, v) = 0, \quad (4.15)$$

[Mol22, S. 222]. In der fiktiven Datenlage der Tabellen 5 und 6 hat jedes Merkmal einen gewissen Einfluss, sodass die Null-Spieler-Eigenschaft hier nicht beobachtet werden kann.

Additivität Das Additivitätsaxiom ist ein zentrales Konzept, das die Konsistenz von Shapley-Werten über die Zusammensetzung von Spielen hinweg beschreibt. Es garantiert, dass für zwei separate Spiele oder Modelle v und w , die Summe der SHAP-Werte eines Merkmals über beide Spiele seinem SHAP-Wert im kombinierten Spiel entspricht:

$$\varphi_i(\mathcal{N}, v + w) = \varphi_i(\mathcal{N}, v) + \varphi_i(\mathcal{N}, w). \quad (4.16)$$

In Machine Learning-Modellen wie dem Random Forest, besonders bei Ensemble-Modellen, ist die Additivität relevant. Ein Random Forest besteht aus unabhängigen Entscheidungsbäumen, die zusammenarbeiten, um Vorhersagen zu treffen. Die SHAP-Werte der einzelnen Bäume können als additive Beiträge betrachtet werden, die den Gesamteinfluss eines Merkmals auf die Modellvorhersage zusammenfassen. [Mol23, S. 32].

5. Komplexitätsbewältigung bei der Berechnung von SHAP-Werten

Die direkte Berechnung von SHAP-Werten kann bei Modellen mit einer großen Anzahl an Merkmalen rechnerisch anspruchsvoll sein. Im Kontext linearer Modelle, wie dem in dieser Arbeit verwendeten Immobilienpreis-Beispiel, ist die vollständige Ermittlung aller möglichen Kombinationen von Merkmalen und deren Beiträgen jedoch nicht notwendig.

In einem linearen Modell sind die Beiträge der einzelnen Merkmale zur Vorhersage additiv und unabhängig voneinander. Dies ermöglicht eine direkte Ableitung der Beiträge jedes Merkmals aus den Modellkoeffizienten. Aufgrund dieser Eigenschaft liefert jedes Merkmal einen konstanten marginalen Beitrag, unabhängig von der Zusammensetzung der restlichen Koalition von Merkmalen. Theoretisch könnte daher für jedes Merkmal nur eine Koalition berechnet werden, um den SHAP-Wert zu bestimmen [Mol23, S. 38]. Dies bestätigen die Tabellen 5 und 6 und die daraus ersichtlichen marginalen Beiträge, die über die jeweiligen Merkmale unabhängig der ihnen beigetretenen Koalition konstant sind. So ist der marginale Beitrag für Merkmal $x_1^{(1)}$ zu allen möglichen Koalitionen stets -125 .

Die Herausforderung bei der Berechnung von SHAP-Werten in realen Szenarien erwächst aus zwei zentralen Problembereichen: der Anzahl der Merkmale und der Notwendigkeit, über diese Merkmale zu integrieren.

Die Anzahl möglicher Koalitionen von Merkmalen wächst exponentiell mit 2^p an, was bei einer großen Anzahl von Merkmalen p schnell zu einer nicht handhabbaren Berechnungskomplexität führt. Hinzu kommt die Schwierigkeit, dass für eine exakte Berechnung der SHAP-Werte eine Integration über die Merkmalsverteilungen erforderlich ist, was jedoch voraussetzt, dass die Verteilung der Merkmale bekannt ist. In der Praxis verfügt man meist nur über eine Stichprobe der Daten, ohne genaue Kenntnis der zugrundeliegenden Verteilungen [Mol23, S. 33].

Um diesen Herausforderungen zu begegnen, wird in diesem Kapitel die Anwendung von Monte Carlo Integration zur Schätzung von SHAP-Werten diskutiert. Diese Methoden ermöglichen es, durch Zufallsstichproben aus den vorhandenen Daten eine Approximation der Verteilungen zu erstellen und dadurch die notwendigen Integrationen näherungsweise auszuführen [Mol23, S. 34]. Darüber hinaus werden Ansätze zur Stichprobenbildung von Koalitionen vorgestellt, die es erlauben, die rechnerische Last zu reduzieren, indem nicht alle Koalitionen betrachtet, sondern repräsentative Stichproben gezogen werden.

5.1. Approximation der marginalen Beiträge mittels Monte Carlo Integration

Statt das Integral über eine unbekannte Verteilung zu berechnen, wie in Gleichung 4.1, nähert die Monte Carlo Integration dieses Integral durch den Durchschnitt einer großen Anzahl zufällig ausgewählter Beobachtungen aus dem Eingaberaum an [Mol23, S. 34]. Die Monte Carlo Integration kann als ein erwartungstreuer Schätzer betrachtet werden, wenn die Anzahl der Zufallsstichproben n hinreichend groß ist. Dies bedeutet, dass mit zunehmendem n die Schätzung des Integrals immer genauer wird und gegen den wahren Wert des Integrals konvergiert. Dies basiert auf dem Gesetz der großen Zahlen, das besagt, dass der Durchschnitt einer großen Anzahl unabhängiger und identisch verteilter Zufallsvariablen gegen den Erwartungswert der Verteilung konvergiert [RC04, S. 83].

Die Zufallsvariable $X_C^{(k)}$, die Merkmale die nicht in der Koalition \mathcal{S} enthalten sind, entfällt und wird durch konkrete Beobachtungen $x_C^{(k)}$ aus der Datenbasis ersetzt, was eine wünschenswerte Vereinfachung darstellt. Das Integral \int wird dadurch zur Summe \sum und die Verteilung \mathbb{P} wird durch eine große Anzahl zufällig ausgewählter Beobachtungen ersetzt und das Ergebnis anschließend über alle ausgewählten Beobachtungen n gemittelt. $\hat{v}_{x^{(i)},f}(\mathcal{S})$ ist somit ein Schätzer für den Wert der Koalition \mathcal{S} und definiert als:

$$\hat{v}_{x^{(i)},f}(\mathcal{S}) = \frac{1}{n} \sum_{k=1}^n \left(f(x_{\mathcal{S}}^{(i)} \cup x_C^{(k)}) - f(x_C^{(k)}) \right) \quad (5.1)$$

Analog zu Gleichung 4.2 ist dann zusammen mit Gleichung 5.1 der marginale Beitrag $\hat{\Delta}_{\mathcal{S},j}$ von Merkmal j zur Koalition \mathcal{S} gegeben als:

$$\begin{aligned} \hat{\Delta}_{\mathcal{S},j} &= \hat{v}_{x^{(i)},f}(\mathcal{S} \cup \{j\}) - \hat{v}_{x^{(i)},f}(\mathcal{S}) \\ &= \frac{1}{n} \sum_{k=1}^n \left(f(x_{\mathcal{S} \cup \{j\}}^{(i)} \cup x_{C \setminus \{j\}}^{(k)}) - f(x_{\mathcal{S}}^{(i)} \cup x_C^{(k)}) \right) \end{aligned} \quad (5.2)$$

und die SHAP-Werte $\hat{\varphi}_j^{(i)}$ über alle möglichen Koalitionen analog zu Gleichung 4.3:

$$\hat{\varphi}_j^{(i)}(\mathcal{N}, f) = \sum_{\mathcal{S} \subseteq \mathcal{N} \setminus \{j\}} \frac{|\mathcal{S}|! \cdot (p - 1 - |\mathcal{S}|)!}{p!} \hat{\Delta}_{\mathcal{S},j}, \quad (5.3)$$

[Mol23, S.36].

5.2. Schätzung von Koalitionen

Obwohl die Monte Carlo Integration aus Gleichung 5.3 eine praktische Methode zur Approximation der benötigten marginalen Beiträge in der SHAP-Wertberechnung bietet, bleibt die Herausforderung, alle möglichen Koalitionen der Merkmale zu evaluieren. Die Anzahl der Koalitionen wächst exponentiell mit der Anzahl der Merkmale. Daher sind Ansätze gefragt, die eine effiziente Schätzung der SHAP-Werte erlauben, ohne jede mögliche Koalition explizit zu berücksichtigen.

Insbesondere für lineare Modelle ohne Interaktionsterme wurde in Kapitel 5 bereits gezeigt, dass die Berechnung einer einzigen Koalition für jedes Merkmal ausreichend ist [Mol23, S. 38]. In einem solchen Modell wird angenommen, dass die Beziehung zwischen den unabhängigen Variablen und der abhängigen Variable additiv ist, das heißt, es gibt keine Terme im Modell, die das Produkt von zwei oder mehr unabhängigen Variablen enthalten, um mögliche Interaktionseffekte zwischen ihnen zu repräsentieren.

Neben dem Linearen SHAP Estimator in Kapitel 5.2.1 wird die Schätzung durch Permutationen in Kapitel 5.2.2 diskutiert. Anstelle der Iteration über alle Koalitionen, werden repräsentative Stichproben zur Berechnung herangezogen.

Beide Verfahren bieten Strategien zur Reduzierung der Berechnungskomplexität, indem sie Annahmen über die Eigenschaften des Modells und der Daten treffen. Weitere Ansätze werden in Kapitel 6.2 angesprochen.

5.2.1. Linearer SHAP Estimator für lineare Modelle

Für lineare Modelle bietet der lineare SHAP Estimator eine direkte und effiziente Methode zur Berechnung der SHAP-Werte. Diese Methode beruht auf der Annahme der Unabhängigkeit der Eingabemerkmale. Unter dieser Voraussetzung können die SHAP-Werte direkt aus den Gewichtungskoeffizienten des linearen Modells abgeleitet werden.

Ein lineares Modell wird typischerweise in der Form $f(x) = \sum_{j=1}^p \beta_j x_j + b$ ausgedrückt, wobei β_j der Gewichtungskoeffizient für das Merkmal j ist und b den Achsenabschnitt (Bias) darstellt. Der lineare SHAP Estimator nutzt diese Koeffizienten, um die Beiträge jedes Merkmals zur Modellvorhersage zu bestimmen. Der SHAP-Wert für ein Merkmal j wird dann definiert als:

$$\varphi_j^{(i)}(f, x) = \beta_j(x_j^{(i)} - \mathbb{E}[X_j]), \quad (5.4)$$

wobei $\mathbb{E}[X_j]$ der Erwartungswert des Merkmals j über den Datensatz ist. Der SHAP-Wert für den Achsenabschnitt (Bias) ist gleich dem Achsenabschnitt des Modells:

$\varphi_0(f, x) = b$ [LL17, S. 6].

Aufgrund der Unabhängigkeit der Eingabemerkmale, kann das arithmetische Mittel aus Kapitel 4.1 Gleichung 4.8 als erwartungstreuer Schätzer für den Erwartungswert verwendet werden:

$$\varphi_j^{(i)}(f, x) = \beta_j \left(x_j^{(i)} - \frac{1}{n} \sum_{k=1}^n x_j^{(k)} \right), \quad (5.5)$$

Das Effizienzaxiom aus Gleichung 4.12 ist erfüllt:

$$\begin{aligned} \sum_{j=1}^p \varphi_j^{(i)}(f, x) &= \sum_{j=1}^p \left(\beta_j x_j^{(i)} - \mathbb{E}[\beta_j X_j] \right) \\ &= \beta_0 + \sum_{j=1}^p \beta_j x_j^{(i)} - \left(\beta_0 + \sum_{j=1}^p \mathbb{E}[\beta_j X_j] \right) \\ &= f(x) - \mathbb{E}[f(X)], \end{aligned} \quad (5.6)$$

[Mol23, S. 48].

Diese Berechnung der SHAP-Werte basiert auf der Idee, dass die Änderung des Modelloutputs, die durch das Abweichen eines Merkmals von seinem Erwartungswert entsteht, direkt durch den entsprechenden Gewichtungskoeffizienten des linearen Modells beschrieben werden kann. Dieser Ansatz ermöglicht eine schnelle und genaue Berechnung der SHAP-Werte für lineare Modelle und ist besonders nützlich, um die Auswirkungen einzelner Merkmale in einem solchen Modell zu interpretieren.

5.2.2. Schätzung durch Permutationen

Der Einsatz von Permutationen zur Schätzung von SHAP-Werten bietet eine praktikable Alternative zur vollständigen Auswertung aller Merkmalskoalitionen. Dieses Verfahren ist insbesondere in Szenarien mit einer hohen Anzahl von Merkmalen von Vorteil, da es die Berechnungslast reduziert, ohne die Genauigkeit der Schätzung wesentlich zu beeinträchtigen. Im Folgenden wird die Methode anhand eines Beispiels illustriert und die Anwendung im Kontext des in Kapitel 4.1 eingeführten linearen Modells beschrieben.

In einem ersten Schritt wird eine zufällige k -te Permutation der Merkmale $o(k)$ gewählt. Beispielsweise könnte $o(k) = (x_2, x_3, x_1)$ eine solche Permutation darstellen. Wird das Merkmal j , für das der SHAP-Wert berechnet werden soll, als das dritte Merkmal $j = 3$ angenommen, ergibt sich der marginale Beitrag $\hat{\Delta}_{o(k),j}$ analog

zu Gleichung 5.2 aus der Differenz der Koalitionen mit und ohne dem betrachteten Merkmal:

$$\hat{\Delta}_{o(k),j} = \hat{v}(\{x_2, x_3\}) - \hat{v}(\{x_2\}) \quad (5.7)$$

Dieser Prozess wird für eine Anzahl von m Permutationen durchgeführt. Die Wahl von m , die kleiner als die Gesamtzahl der Merkmale sein kann, hängt von der gewünschten Approximationsgenauigkeit ab. Eine größere Anzahl von Permutationen m führt zu einer präziseren Annäherung an den tatsächlichen SHAP-Wert.

Die geschätzten marginalen Beiträge $\hat{\Delta}_{o(k),j}$ werden dann über die m Permutationen analog zu Gleichung 5.3 gemittelt:

$$\hat{\varphi}_j^{(i)}(\mathcal{N}, f) = \frac{1}{m} \sum_{k=1}^m \hat{\Delta}_{o(k),j}, \quad (5.8)$$

Durch diese Methodik wird der Berechnungsaufwand bei der Ermittlung von SHAP-Werten signifikant verringert, was besonders bei Modellen mit einer großen Anzahl von Merkmalen von Bedeutung ist. Der hier vorgestellte Ansatz ermöglicht es, mit einer begrenzten Anzahl von Permutationen eine aussagekräftige Schätzung der SHAP-Werte zu erhalten [Mol23, S. 39].

Zusätzlich zur Mittelung der geschätzten marginalen Beiträge bietet die Methode der Permutationen die Möglichkeit, die Effekte von Vorwärts- und Rückwärtspropagation zu untersuchen, indem die Reihenfolge der Merkmale sowohl in ihrer ursprünglichen als auch in umgekehrter Abfolge betrachtet wird. Für eine detaillierte Darstellung dieser Technik und ihrer Auswirkungen auf die SHAP-Wertberechnung sei auf die weiterführende Literatur verwiesen [Mol23, S. 39f].

6. Praktische Anwendung von SHAP auf lineare Modelle

In diesem Kapitel wird der Einsatz des SHAP-Frameworks zur Interpretation linearer Modelle im Kontext des maschinellen Lernens untersucht. Lineare Modelle, gekennzeichnet durch ihre Transparenz und einfache Struktur, bilden oft die Basis für das Verständnis komplexerer Algorithmen. Dennoch bleibt die Herausforderung bestehen, die Beiträge individueller Merkmale zur Modellvorhersage zu quantifizieren und zu interpretieren.

Die Anwendung von SHAP-Werten ermöglicht es, diesen Herausforderungen zu begegnen und Einblicke in die Modellvorhersagen zu gewähren, die über traditionelle Methoden hinausgehen. Dieses Kapitel führt in die Grundlagen des `shap`-Pakets ein, demonstriert dessen Anwendung auf einen spezifischen Datensatz und diskutiert die Berechnung sowie Interpretation der resultierenden SHAP-Werte.

6.1. Lineare Modelle als analytische Grundlage

In linearen Regressionsmodellen wird die Zielgröße als eine gewichtete Kombination der Eingangsmerkmale bestimmt. Die einfache lineare Struktur dieser Modelle erleichtert das Verständnis der Beziehungen zwischen den Eingangsdaten und den Vorhersagen.

Lineare Modelle sind ein grundlegendes Werkzeug in der statistischen Modellierung und dienen dazu, das Verhältnis zwischen einer abhängigen Variablen, die üblicherweise mit $y^{(i)}$ bezeichnet wird, und einem oder mehreren Prädiktoren, den unabhängigen Variablen x_i , zu erfassen. Diese Beziehungen werden mittels linearer Gleichungen dargestellt, die für jede einzelne Beobachtung i im Datensatz folgendermaßen formuliert werden können:

$$y^{(i)} = \beta_0 + \sum_{j=1}^p \beta_j x_j^{(i)} + \epsilon^{(i)}, \quad (6.1)$$

wobei das Ergebnis, das von einem linearen Modell für eine gegebene Beobachtung vorhergesagt wird, sich als Summe der mit Gewichten β_j versehenen Merkmale p ergibt.

Hierbei stellt $y^{(i)}$ den beobachteten Wert der abhängigen Variablen für die Beobachtungseinheit i dar. Der Term β_0 ist der Achsenabschnitt oder y-Achsenabschnitt des Modells, welcher den erwarteten Wert von y darstellt, wenn alle unabhängigen

Variablen x null sind. Die Summe $\sum_{j=1}^p \beta_j x_j^{(i)}$ berechnet sich aus den Produkten der Koeffizienten β_j und den Werten der unabhängigen Variablen $x_j^{(i)}$ für jede Beobachtungseinheit i und jeden Prädiktor j , wobei die Koeffizienten β_j den geschätzten Einfluss der entsprechenden unabhängigen Variablen auf die abhängige Variable beschreiben.

Der Fehlerterm $\epsilon^{(i)}$ steht für die Residuen, also die Differenzen zwischen den beobachteten und durch das Modell geschätzten Werten von $y^{(i)}$. Es wird angenommen, dass diese Fehler normalverteilt sind, was bedeutet, dass Abweichungen in beiden Richtungen um den Mittelwert (hier Null) mit abnehmender Wahrscheinlichkeit für größere Fehler auftreten [Mol22, S. 37].

In einem linearen Modell stellt der Achsenabschnitt die Basislinie dar, an der die Auswirkungen aller anderen Merkmale gemessen werden. Dieser Wert gibt an, was das Modell für die Zielvariable vorhersagen würde, wenn alle anderen Merkmale nicht vorhanden wären – der Ausgangspunkt der Vorhersage für einen Datensatz, in dem alle anderen Variablen auf null gesetzt sind. Es ist wichtig zu erwähnen, dass der Achsenabschnitt für sich genommen nicht immer eine praktische Bedeutung hat, da es selten vorkommt, dass alle Variablen tatsächlich den Wert null annehmen. Die wahre Aussagekraft des Achsenabschnitts tritt zutage, wenn die Daten so standardisiert wurden, dass ihre Mittelwerte bei null und die Standardabweichung bei eins liegen. Unter diesen Umständen repräsentiert der Achsenabschnitt die erwartete Zielvariable für einen hypothetischen Fall, in dem alle Merkmale ihren Durchschnittswert aufweisen.

Bei der Betrachtung einzelner Merkmale innerhalb des Modells sagt das Gewicht β_j eines Merkmals, um wie viel sich die Zielvariable $y^{(i)}$ ändert, wenn das Merkmal $x_j^{(i)}$ um eine Einheit erhöht wird – und zwar unter der Annahme, dass alle anderen Merkmale unverändert bleiben. Dies ermöglicht es, den isolierten Effekt eines jeden Merkmals auf die Vorhersage zu verstehen [Mol22, S. 39].

Die optimalen Gewichte, oder Koeffizienten, eines linearen Regressionsmodells werden üblicherweise durch ein Verfahren bestimmt, das als Methode der kleinsten Quadrate (engl. *Ordinary Least Squares*, OLS) bekannt ist. Diese Methode sucht die Koeffizienten β_0, \dots, β_p , welche die Summe der quadrierten Differenzen zwischen den beobachteten Werten der Zielvariablen $y^{(i)}$ und den von dem Modell vorhergesagten Werten minimieren:

$$\hat{\beta} = \arg \min_{\beta_0, \dots, \beta_p} \sum_{i=1}^n \left(y^{(i)} - \left(\beta_0 + \sum_{j=1}^p \beta_j x_j^{(i)} \right) \right)^2. \quad (6.2)$$

Das Ergebnis der Minimierung, $\hat{\beta}$ stellt den Vektor der geschätzten Koeffizienten

dar [Mol22, S. 37]. In der vorliegenden Arbeit wird das Python-Paket `scikit-learn`¹ verwendet, um die lineare Regression durchzuführen und die Koeffizienten $\hat{\beta}$ zu bestimmen.

6.2. Einführung in das `shap` Python-Paket

Das Python-Paket `shap`² ist eine Open-Source-Bibliothek, die es Nutzern ermöglicht, die Auswirkungen von Merkmalen auf Vorhersagen von maschinellen Lernmodellen zu interpretieren und zu visualisieren. Entwickelt wurde die Bibliothek ursprünglich von Scott Lundberg und weiteren Mitwirkenden im Rahmen der Forschungsarbeit an der University of Washington [LL17]. Das Paket basiert auf dem Konzept der Shapley-Werte aus der kooperativen Spieltheorie und überträgt diese auf den Kontext des maschinellen Lernens, um als Tool für die Interpretierbarkeit und Erklärbarkeit von Modellvorhersagen zu dienen.

Die Kernfunktion des `shap`-Pakets ist die Berechnung von SHAP-Werten, welche die Auswirkung der Einzelmerkmale auf die Modellvorhersage quantifizieren. Jeder SHAP-Wert ist ein Maß dafür, wie viel jedes Merkmal zur Vorhersage beigetragen hat, im Vergleich zu einer durchschnittlichen Vorhersage über den gesamten Datensatz. Diese Werte sind besonders wertvoll, weil sie ein Maß für die Bedeutung jedes Merkmals liefern, das sowohl lokal (für einzelne Vorhersagen) als auch global (über das gesamte Modell) interpretiert werden kann.

Mit `shap` können Benutzer die Vorhersagen einer Vielzahl von Modellen interpretieren, von linearen Modellen bis hin zu komplexen Konstrukten wie tiefe neuronale Netzwerke. Die Bibliothek bietet eine vielseitige Auswahl an Visualisierungsoptionen, darunter Beeswarm-Plots, Dependence-Plots und Bar-Plots, die es ermöglichen, die SHAP-Werte intuitiv zu verstehen. Eine Übersicht aller Visualisierungsoptionen ist in der Dokumentation des Pakets zu finden³. Diese Visualisierungen erleichtern es, Muster und Beiträge einzelner Merkmale zu erkennen, was nicht nur wertvolle Einblicke in die Leistung des Modells bietet, sondern auch zu faireren und transparenteren Modellentscheidungen führen kann.

Im Kapitel 5.2.1 wurde bereits der `LinearExplainer` aus dem `shap`-Paket vorgestellt, ein Beispiel für die verschiedenen Estimators, die das Paket in Form von Explainern bereitstellt. Das Paket bietet eine Vielzahl von Explainern, die auf unterschiedliche Modelltypen zugeschnitten sind. Einer der bemerkenswerten Aspekte von `shap` ist der `auto` Modus des Estimators, der automatisch den am besten geeigneten Explainer für das gegebene Modell auswählt. Diese Funktion ist besonders nützlich, da sie die Komplexität der Auswahl des richtigen Explainers reduziert und den Anwendungsprozess vereinfacht. Speziell für Modelle mit ca. 15 Merkmalen⁴ wählt der `auto`

¹<https://scikit-learn.org>

²<https://shap.readthedocs.io>

³<https://shap.readthedocs.io/en/latest/api.html#plots>

⁴https://github.com/shap/shap/blob/master/shap/explainers/_exact.py

Modus den exakten Explainer, der präzise SHAP-Werte auf Grundlage aller Daten und Koalitionen berechnet, was für Modelle mit einer geringeren Anzahl von Merkmalen effizient und praktikabel ist [Mol23, S. 40f]. Eine Übersicht der zur Verfügung stehenden `shap`-Explainern ist in der Dokumentation des Pakets zu finden⁵.

6.3. Einführung in den Datensatz

Der Concrete Compressive Strength Datensatz ist eine umfassende Sammlung von Daten, die die Druckfestigkeit von Beton in Bezug auf verschiedene Bestandteile und das Alter des Betons untersucht. Die Bestandteile umfassen Zement, Hochofenschlacke, Flugasche, Wasser, Superplastifikator, groben Zuschlag und feinen Zuschlag [Yeh07].

Ziel der Regression: Das Ziel ist es, die Druckfestigkeit von Beton in Megapascal basierend auf seiner Zusammensetzung und dem Alter vorherzusagen. Diese Vorhersage ist entscheidend, da Beton das Fundament der modernen Welt bildet und seine Festigkeit für die Sicherheit und Langlebigkeit von Bauwerken von größter Bedeutung ist.

Der Datensatz umfasst folgende Variablen:

- **cement (Zement):** Menge an Zement (kg in einem m³ Gemisch). Zement ist ein Hauptbestandteil von Beton und wesentlich für dessen Festigkeit.
- **blast (Hochofenschlacke):** Menge an Hochofenschlacke (kg in einem m³ Gemisch). Schlacke kann die Festigkeit und Haltbarkeit von Beton verbessern.
- **ash (Flugasche):** Menge an Flugasche (kg in einem m³ Gemisch). Flugasche wird als Ersatz für Zement verwendet und beeinflusst die Verarbeitbarkeit und Festigkeit.
- **water (Wasser):** Menge an Wasser (kg in einem m³ Gemisch). Wasser ist für die Hydratation des Zements und die Konsistenz des Betons notwendig.
- **superplasticizer (Superplastifikator):** Menge an Superplastifikator (kg in einem m³ Gemisch). Superplastifikatoren verbessern die Fließfähigkeit und Verarbeitbarkeit von Beton.
- **coarse (Grober Zuschlag):** Menge an grobem Zuschlag (kg in einem m³ Gemisch). Grober Zuschlag trägt zur Stabilität und Struktur des Betons bei.
- **fine (Feiner Zuschlag):** Menge an feinem Zuschlag (kg in einem m³ Gemisch). Feiner Zuschlag beeinflusst die Dichte und die Oberflächeneigenschaften des Betons.

⁵<https://shap.readthedocs.io/en/latest/api.html#explainers>

- **age (Alter)**: Alter des Betons in Tagen. Das Alter hat einen signifikanten Einfluss auf die Festigkeit des Betons.
- **strength (Druckfestigkeit)**: Die tatsächliche Druckfestigkeit von Beton (MPa). Dies ist die Zielvariable, die modelliert wird.

Die Bedeutung dieses Themas liegt in der zentralen Rolle, die Beton im Bauwesen spielt. Als eines der am meisten verwendeten Materialien weltweit, ist die genaue Vorhersage seiner Festigkeit von entscheidender Bedeutung für die Planung und den Bau sicherer und langlebiger Strukturen. Dieser Datensatz bietet daher wertvolle Einblicke für Ingenieure und Forscher, um die Eigenschaften und das Verhalten von Beton besser zu verstehen und zu optimieren.

6.4. Explorative Datenanalyse & Datenaufbereitung

Der Datensatz wurde in Python mithilfe der Bibliothek `pandas` als `Dataframe` eingelesen. Der vollständige Quellcode für das Einlesen der Daten sowie alle weiteren Analyseschritte ist im Anhang A.3 dieser Arbeit zu finden.

Tabelle 7 zeigt die ersten fünf Beobachtungen des Datensatzes:

Tabelle 7.: Auszug aus dem Concrete Compressive Strength Datensatz.

Index	cement	blast	ash	water	superplasticizer	coarse	fine	age	strength
0	540.0	0.0	0.0	162.0	2.5	1040.0	676.0	28	79.986111
1	540.0	0.0	0.0	162.0	2.5	1055.0	676.0	28	61.887366
2	332.5	142.5	0.0	228.0	0.0	932.0	594.0	270	40.269535
3	332.5	142.5	0.0	228.0	0.0	932.0	594.0	365	41.052780
4	198.6	132.4	0.0	192.0	0.0	978.4	825.5	360	44.296075

Quelle: Eigene Darstellung, A.3.

Tabelle 8.: Statistische Übersicht des Concrete Compressive Strength Datensatzes.


Variable	mean	std	min	25%	50%	75%	max
cement	278.629	104.345	102.0	190.68	265.0	349.0	540.0
blast	72.043	86.171	0.0	0.0	20.0	142.5	359.4
ash	55.535	64.207	0.0	0.0	0.0	118.27	200.1
water	182.074	21.341	121.75	166.61	185.7	192.94	247.0
superplasticizer	6.032	5.92	0.0	0.0	6.1	10.0	32.2
coarse	974.376	77.58	801.0	932.0	968.0	1031.0	1145.0
fine	772.687	80.34	594.0	724.3	780.0	822.2	992.6
age	45.857	63.735	1.0	7.0	28.0	56.0	365.0
strength	35.250	16.285	2.332	23.524	33.798	44.868	82.599

Quelle: Eigene Darstellung, A.3.

Tabelle 8 offenbart eine signifikante Variabilität und Bandbreite in den Werten aller

Variablen. Um eine gleichmäßigere Verteilung für die Regressionsanalyse zu erzielen und den Einfluss von Ausreißern zu reduzieren, wurde eine logarithmische Transformation auf die Daten angewendet. Abbildung 3 zeigt das Minimum, das untere Quartil, den Median, das obere Quartil und das Maximum der jeweiligen Merkmale vor und nach der logarithmischen Transformation.

Abbildung 3.: Boxplot der Merkmale vor und nach der Log-Transformation.

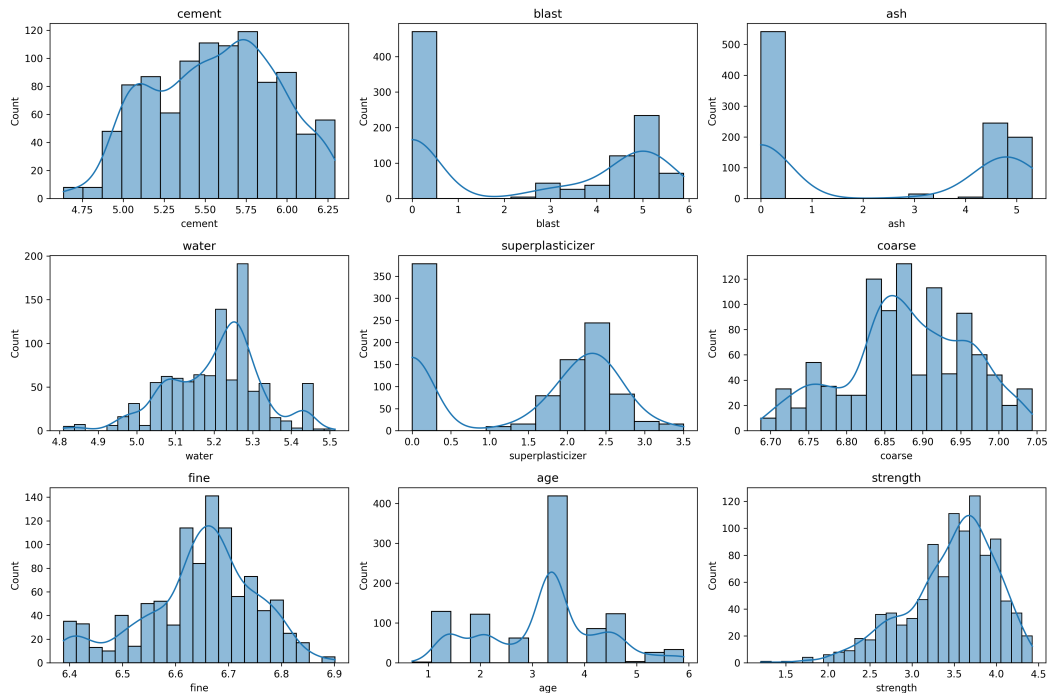


Quelle: Eigene Darstellung, A.3.

Diese Transformation hilft, die Skalierung der Variablen zu vereinheitlichen und die Datenverteilung zu normalisieren, was für die Effektivität des Regressionsmodells vorteilhaft ist.

Abbildung 4 zeigt die Häufigkeitsverteilung aller Merkmale des Datensatzes nach der logarithmischen Transformation.


Abbildung 4.: Verteilungen der Merkmale.



Quelle: Eigene Darstellung, A.3.

Die Korrelationsmatrix, dargestellt in Abbildung 5, quantifiziert die Beziehungen zwischen den einzelnen Bestandteilen des Betons und der Zielvariablen der Betondruckfestigkeit. Die Koeffizienten bewegen sich zwischen -0.61 und 0.63, was auf unterschiedlich starke Korrelationen hinweist. Ein markantes Beispiel ist der positive Wert von 0.63 zwischen Asche und Wasser, was eine starke direkte Beziehung nahelegt, während der Wert von -0.61 zwischen Wasser und Superplastifikator auf eine starke umgekehrte Beziehung hindeutet. Die Zielvariable der Betondruckfestigkeit zeigt die stärkste direkte Korrelation mit dem Zementgehalt (0.46), was darauf schließen lässt, dass ein höherer Zementanteil tendenziell zu einer stärkeren Betonmischung führt. Diese Korrelationsmuster sind essentiell für die Modellentwicklung, da sie Aufschluss darüber geben, welche Mischungsbestandteile einen bedeutenden Einfluss auf die Betondruckfestigkeit haben könnten.

Abbildung 5.: Korrelationsmatrix der Merkmale im Datensatz.



Quelle: Eigene Darstellung, A.3.

6.5. Modellierung der linearen Regression

Um die Beziehung zwischen den unabhängigen Variablen und der Zielvariablen zu untersuchen, wurde ein lineares Regressionsmodell aufgestellt. Zur Bewertung der Vorhersageleistung des Modells und zur Vermeidung von Overfitting wurde der Datensatz in zwei Teile aufgeteilt: 80% der Daten dienten als Trainingsset zur Anpassung

sung des Modells, während die restlichen 20% als Testset verwendet wurden, um die Modellleistung anhand neuer, unbekannter Daten zu evaluieren. Diese Aufteilung erfolgte zufällig, aber reproduzierbar, durch Festlegen eines Seed-Werts für den Zufallszahlengenerator, der eine konsistente Teilung des Datensatzes ermöglicht.

Das Trainingsset wurde dazu verwendet, die Koeffizienten der linearen Regression zu schätzen, die den Einfluss jeder unabhängigen Variablen auf die Zielvariable quantifizieren. Anschließend wurde das Modell mit dem Testset geprüft, um seine Vorhersagegenauigkeit zu bewerten. Die Leistung des Modells wurde anhand von Metriken wie dem mittleren quadratischen Fehler (Mean Squared Error, MSE) gemessen, die ein Maß für die Abweichung der Modellvorhersagen von den tatsächlichen Werten darstellen.

Codeauschnitt 6.1 und 6.2 zeigen das Trainieren und Testen der zugrundeliegenden Daten eines linearen Regressionsmodells:

Listing 6.1: Initialisierung eines linearen Regressionsmodells, A.3.

```
1 def model(X: pd.DataFrame, y: pd.Series) -> (LinearRegression, pd.DataFrame):
2     """
3     Fits a Linear Regression model to the given data.
4
5     Args:
6     X (pd.DataFrame): The feature matrix.
7     y (pd.Series): The target variable.
8
9     Returns:
10    LinearRegression: The fitted Linear Regression model.
11    DataFrame: The coefficients as DataFrame.
12    """
13    model = LinearRegression()
14    model.fit(X, y)
15
16    cdf = pd.DataFrame(model.coef_.round(5), X.columns, columns=['Coefficients'])
17    cdf.loc['Intercept'] = model.intercept_.round(5)
18
19    return model, cdf
```

Listing 6.2: Training und Testen eines linearen Regressionsmodells, A.3.

```
1 X = df.drop(['strength'], axis=1)
2 y = df['strength']
3
4 X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.20,
5     random_state=42)
6
7 linreg, coef = model(X=X_train, y=y_train)
8 y_pred = linreg.predict(X_test)
```

6.6. Berechnung von SHAP-Werten

Um SHAP-Werte zu berechnen, wird zunächst ein SHAP-Explainer-Objekt erstellt. In diesem Fall wird der Explainer von SHAP mit dem trainierten linearen Regressi-

onsmodell und dem Trainingsdatensatz initialisiert. Anschließend werden die SHAP-Werte für die Testdaten berechnet, um die Beiträge der einzelnen Merkmale zu analysieren. Der Typ des Explainers wird durch die Art des übergebenen Modells bestimmt. Da in diesem Beispiel ein lineares Modell verwendet wird, wird automatisch ein geeigneter explainer für lineare Modelle ausgewählt.

Das folgende Codeausschnitt 6.3 zeigt die Initialisierung des SHAP-Explainers und die Berechnung der SHAP-Werte:

Listing 6.3: Berechnung von SHAP-Werten für das lineare Regressionsmodell, A.3.

```
1 explainer = shap.Explainer(linreg, X_train)
2 shap_values = explainer(X_test)
```

Das explainer-Objekt enthält neben den SHAP-Werten (`.values`), die die Einflüsse der einzelnen Merkmale der Testmenge auf die Modellvorhersage quantifizieren, auch die Basiswerte (`.base_values`), die die durchschnittliche Vorhersage des Modells darstellen, und die ursprünglichen Merkmalsausprägungen (`.data`), die für die Berechnung dieser Werte verwendet wurden [Mol23, S. 51].

Dies bildet die Grundlage für den nächsten entscheidenden Schritt: die Visualisierung und tiefere Analyse dieser Werte. Die SHAP-Bibliothek bietet eine Reihe von leistungsstarken Visualisierungswerkzeugen, die es ermöglichen, die Auswirkungen der einzelnen Merkmale auf die Modellvorhersagen intuitiv und verständlich darzustellen.

Im folgenden Kapitel 7 werden diese Visualisierungen im Detail vorgestellt. Anhand von Beeswarm-Plots, Dependence-Plots und Bar-Plots werden die Ergebnisse der SHAP-Analyse dargestellt, die ein umfassendes Bild der Einflüsse und Wichtigkeiten der verschiedenen Merkmale im Kontext des linearen Regressionsmodells bieten.

Die Grafiken wurden mithilfe der `shap`-Bibliothek wie folgt erzeugt:

Listing 6.4: Erzeugen der SHAP Plots, A.3.

```
1 def plot_shap(shap_values: shap.Explanation, model: LinearRegression, X: pd.
   DataFrame, idx: int) -> None:
2     """
3     Creates and saves SHAP beeswarm, bar, and waterfall plots.
4
5     Args:
6         shap_values (shap.Explanation): SHAP values.
7         model (LinearRegression): The Linear Regression model.
8         X (pd.DataFrame): The background data for partial dependence plot.
9         idx (int): Index for the SHAP waterfall plot.
10    """
11    plt.figure(figsize=(12, 10))
12    shap.plots.beeswarm(shap_values)
13    plt.tight_layout()
14    plt.savefig('images/shap_beeswarm_plot.png', dpi=300)
15
16    plt.figure(figsize=(12, 10))
17    shap.plots.bar(shap_values)
```

```
18 plt.tight_layout()
19 plt.savefig('images/shap_bar_plot.png', dpi=300)
20
21 plt.figure(figsize=(12, 10))
22 shap.plots.waterfall(shap_values[idx])
23 plt.tight_layout()
24 plt.savefig('images/shap_waterfall_plot.png', dpi=300)
25
26 plt.figure(figsize=(12, 10))
27 shap.plots.partial_dependence("cement", model.predict, X,
28                               model_expected_value=True,
29                               feature_expected_value=True,
30                               ice=False,
31                               shap_values=shap_values[idx:idx+1,:])
32 plt.tight_layout()
33 plt.savefig('images/shap_dependence_plot.png', dpi=300)
```

7. Ergebnisse

In diesem Kapitel werden die Resultate der angewandten linearen Regressionsanalyse zur Vorhersage der Druckfestigkeit von Beton dargestellt. Die Analyse berücksichtigt sowohl die geschätzten Koeffizienten des linearen Modells als auch verschiedene Evaluierungsmetriken wie den mittleren absoluten Fehler (MAE), den mittleren quadratischen Fehler (MSE) sowie die Bestimmtheitsmaße (R^2) für Trainings- und Testdaten. Diese Metriken liefern Aufschluss über die Güte des Modells und die Präzision der Vorhersagen. Zunächst werden die Koeffizienten des linearen Modells auf herkömmliche Weise interpretiert. Anschließend wird gezeigt, wie SHAP-Werte eine tiefere und detailliertere Analyse ermöglichen.

7.1. Lineares Regressionmodell

Die Koeffizienten des Modells, die in Tabelle 9 aufgeführt sind, zeigen, wie stark sich eine Einheitänderung jedes unabhängigen Merkmals auf die Beton-Druckfestigkeit auswirkt, unter der Vorraussetzung, dass alle anderen Merkmale null sind.

Positive Koeffizienten deuten auf eine Erhöhung der Beton-Druckfestigkeit bei Zunahme der Variablen hin, während negative Koeffizienten eine Verringerung anzeigen. Der Intercept-Wert repräsentiert die geschätzte Beton-Druckfestigkeit, wenn alle unabhängigen Variablen den Wert Null annehmen.

Daraus ergibt sich zusammen mit Gleichung 6.1 die Regressionsgerade für das Modell.

Tabelle 9.: Koeffizienten des linearen Regressionsmodells.

Merkmal (β_j)	Koeffizient
Intercept (β_0)	4.36596
cement	0.75091
blast	0.06610
ash	0.02683
water	-0.92315
superplasticizer	0.06410
coarse	0.08554
fine	-0.31901
age	0.29090

Quelle: Eigene Darstellung, A.3.

Die Modellmetriken, dargestellt in Tabelle 10, geben Auskunft über die Vorhersagegenauigkeit und die Anpassungsgüte des Modells. Der MAE und RMSE liefern dabei

Informationen über die durchschnittliche Größe der Fehler in den Vorhersagen. Im Mittel weicht die Prognose um 0.19 vom tatsächlichen Wert ab. Die R^2 -Werte zeigen, wie gut das Modell die Varianz der Zielvariable erklärt.


Tabelle 10.: Modellmetriken des linearen Regressionsmodells.

Metrik	Wert
Mean Absolute Error (MAE)	0.19
Mean Squared Error (MSE)	0.06
Root Mean Squared Error (RMSE)	0.24
Training Score (R^2)	0.7852
Test Score (R^2)	0.8155

Quelle: Eigene Darstellung, A.3.

Darüber hinaus wurden die tatsächlichen gegen die vorhergesagten Werte in Abbildung 6 visualisiert, die eine allgemeine Einschätzung der Modellgenauigkeit ermöglicht. Ein weiterer wichtiger Aspekt sind die Residuen des Modells. Die Residuen, also die Differenzen zwischen den tatsächlichen und vorhergesagten Werten, sollten idealerweise zufällig um Null verteilt sein und keine Muster aufweisen, die auf eine Verletzung der Modellannahmen hindeuten könnten.

Abbildung 6.: Residuenanalyse: Beziehung zwischen Vorhersagen und Abweichungen.



Quelle: Eigene Darstellung, A.3.

7.2. Interpretation der Koeffizienten & Permutation Feature Importance

In diesem Abschnitt wird die herkömmliche Interpretation der Modellkoeffizienten genauer betrachtet. Die Koeffizienten eines linearen Modells repräsentieren die Änderung der abhängigen Variable (in diesem Fall die Druckfestigkeit von Beton) für eine Einheitänderung der unabhängigen Variablen, unter der Annahme, dass alle anderen Variablen konstant gehalten werden.


Es ist wichtig zu betonen, dass diese Koeffizienten eine bedingte Assoziation beschreiben. Das bedeutet, sie quantifizieren die Variation der Druckfestigkeit, wenn

eine bestimmte unabhängige Variable verändert wird, während alle anderen unabhängigen Variablen konstant gehalten werden. Diese Interpretation berücksichtigt die Wechselwirkungen zwischen den verschiedenen unabhängigen Variablen im Modell.

Es ist entscheidend zu verstehen, dass die Koeffizienten nicht als marginale Beiträge betrachtet werden sollten. Das bedeutet, sie beschreiben nicht die Beziehung zwischen den Variablen unabhängig von anderen Einflussfaktoren. Stattdessen zeigen sie, wie sich die Druckfestigkeit ändert, wenn eine bestimmte unabhängige Variable variiert wird, während alle anderen konstant gehalten werden.

Abbildung 7 zeigt die Koeffizienten des Regressionsmodells. Die Stärke des Einflusses einer unabhängigen Variable auf die abhängige Variable hängt von der Größe der Merkmalsausprägung ab. Ob ein bestimmtes Merkmal einen großen oder kleinen Einfluss auf die abhängige Variable hat, hängt von den spezifischen Werten der Merkmale und der Streuung der Merkmalsausprägungen ab.

Abbildung 7.: Koeffizienten des linearen Regressionsmodells.




Quelle: Eigene Darstellung, A.3.

Die logarithmische Transformation der Merkmale hat dieses Problem bereits teilweise gelöst, indem sie die Skalierung der Daten angepasst hat und alle Merkmale auf eine einheitlichen Skala transformiert hat. Daraus lassen sich erste Schlüsse der Merkmalsrelevanz ableiten. Im Vergleich zu allen anderen Koeffizienten tragen die Merkmale ash, superplasticizer, blast und coarse nur wenig zur abhängigen Variable

bei. Das obige Diagramm gibt Aufschluss über die Abhängigkeiten zwischen einem bestimmten Merkmal und der Zielvariablen, wenn alle anderen Merkmale konstant bleiben. Eine Erhöhung von cement führt zu einer Erhöhung der Druckfestigkeit. Im Gegensatz dazu führt eine Erhöhung von water zu einer Verringerung der Druckfestigkeit, immer unter der Voraussetzung, dass alle anderen Merkmale konstant bleiben.

Abbildung 8 zeigt einen Effektplot für die erste Beobachtung im Testdatensatz. Dieser ermöglicht es, den individuellen Effekt eines Merkmals auf die Vorhersage in Relation zur gesamten Verteilung aller Beobachtungen zu veranschaulichen. Die graphische Darstellung zeigt die Auswirkungen der Merkmale auf die Vorhersage für diese spezielle Beobachtung. Jedes Merkmal wird durch ein rotes Kreuz markiert, das den Effekt (Koeffizient multipliziert mit der Merkmalsausprägung) dieses Merkmals auf die Vorhersage darstellt. Die horizontale Position des Kreuzes zeigt den Wert des Effekts, während die vertikale Position das entsprechende Merkmal repräsentiert.

Abbildung 8.: Effektplot für Beobachtung $x^{(0)}$ der Testmenge.



Quelle: Eigene Darstellung, A.3.

Innerhalb des Boxplots zeigt die Box die Interquartilspanne (IQR), während der horizontale Strich in der Mitte der Box den Median repräsentiert. Die Whiskers (die Linien oberhalb und unterhalb der Box) zeigen die Streuung der Daten, während Ausreißer als einzelne Punkte außerhalb der Whiskers dargestellt werden. Dieser Teil des Plots ermöglicht es, den Effekt eines Merkmals in Bezug auf seine Verteilung innerhalb des gesamten Datensatzes zu interpretieren.


Der Effektplot ist ein nützliches Werkzeug, um zu verstehen, wie sich Änderungen in den Merkmalswerten auf die Vorhersage auswirken und wie dieser individuelle Effekt im Vergleich zur gesamten Datenverteilung steht.

Im Anschluss an die Analyse der Koeffizienten des linearen Regressionsmodells wird die Merkmalsrelevanz näher betrachtet. Ein bewährtes Verfahren zur Bestimmung

der Merkmalsrelevanz ist die sogenannte Permutation Feature Importance. Diese Methode misst die Veränderung im Vorhersagefehler des Modells nach der zufälligen Vertauschung der Werte eines bestimmten Merkmals. Ein Merkmal gilt als wichtig, wenn die Vertauschung seiner Werte den Modellfehler erhöht, da das Modell stark auf dieses Merkmal für seine Vorhersagen angewiesen ist. Umgekehrt wird ein Merkmal als unwichtig betrachtet, wenn die Vertauschung seiner Werte den Modellfehler unverändert lässt, da das Modell das Merkmal für seine Vorhersagen ignoriert [Mol22, S. 157].

Abbildung 9 zeigt die Merkmalsrelevanz auf der Test- und Trainingsmenge anhand der Veränderung des mittleren quadratischen Fehlers des Modells:

Abbildung 9.: Permutation Feature Importance.



Quelle: Eigene Darstellung, A.3.

Es ist festzustellen, dass die Merkmale coarse, fine und ash keine erhebliche Veränderung im mittleren quadratischen Fehler des Modells hervorrufen und diese somit im Vergleich zu den anderen Merkmalen als eher irrelevant angesehen werden können.


7.3. Interpretation mit SHAP

Durch die Verwendung von SHAP-Werten wird es möglich, die Beiträge der einzelnen Merkmale zur Vorhersageleistung des Modells nicht nur auf globaler Ebene, sondern auch auf lokaler, individueller Ebene zu verstehen. SHAP-Werte berücksichtigen die Wechselwirkungen zwischen den Merkmalen und quantifizieren den Beitrag jedes Merkmals zur Abweichung der Prognose im Mittel. Dies ermöglicht eine präzisere Interpretation, da die SHAP-Werte den Einfluss eines Merkmals auf die Vorhersage unter Berücksichtigung aller anderen Merkmale anzeigen.

7.3.1. Lokale Interpretation

Die lokale Interpretation konzentriert sich auf das Verständnis der Vorhersagen für eine einzelne Beobachtung aus dem Datensatz.

Im Partial Dependence Plot der Abbildung 10 wird die Beziehung zwischen dem Merkmal cement und der Zielvariable für die spezifische Beobachtung $x^{(0)}$ aus dem

Abbildung 10.: SHAP Partial Dependence Plot für Beobachtung $x^{(0)}$ der Testmenge.

Quelle: Eigene Darstellung, A.3.


Testmenge visualisiert. Die blaue Linie im Diagramm repräsentiert die modellierte Abhängigkeit der Vorhersage vom Merkmal cement, unter Konstanthaltung aller anderen Merkmale. Der schwarze Punkt markiert die tatsächliche Ausprägung des Merkmals cement (5.035) für die betrachtete Beobachtung und die korrespondierende Vorhersage des linearen Regressionsmodells. Die rote Linie illustriert die marginale Abweichung der Vorhersage von der durchschnittlichen Modellprognose $\mathbb{E}[f(X)] = 3.421$, ausgehend vom beobachteten Wert von cement.

Die Anordnung des schwarzen Punktes entlang der funktionalen Beziehung gibt den spezifischen Wert von cement an und reflektiert, wie dieser Wert in den Kontext des gesamten Wertebereichs dieses Merkmals eingeordnet wird. Die vertikale Distanz zwischen der durchschnittlichen Vorhersage (dargestellt durch die horizontale gestrichelte Linie) und dem Punkt auf der funktionalen Abhängigkeit (blaue Linie) zeigt den Einfluss des Merkmals cement auf die individuelle Vorhersage im Vergleich zum Modellmittelwert. Dieser Einfluss verkörpert den marginalen Beitrag des Merkmals cement zur Prognoseabweichung für die ausgewählte Beobachtung.

Während der Partial Dependence Plot einen wertvollen Einblick in die Modellabhängigkeit von einzelnen Merkmalen bietet, ist für ein umfassendes Verständnis der Modellvorhersage eine ganzheitliche Betrachtung aller Merkmale notwendig. Der SHAP Waterfall Plot adressiert diese Notwendigkeit, indem er eine kumulative Darstellung aller marginalen Beiträge liefert. Jedes Merkmal wird in Form einer Sequenz von

Beiträgen visualisiert, beginnend mit dem Basiswert der Vorhersage, welcher durch die Addition oder Subtraktion der individuellen Merkmalsbeiträge schrittweise zur finalen Vorhersage modifiziert wird.

Abbildung 11.: SHAP Waterfall Plot für Beobachtung $x^{(0)}$ der Testmenge.



Quelle: Eigene Darstellung, A.3.

In Abbildung 11 ist ein Waterfall Plot der ersten Beobachtung $x^{(0)}$ dargestellt, der die Zerlegung einer einzelnen Modellvorhersage zeigt. Der Plot beginnt mit dem Basiswert $\mathbb{E}[f(X)] = 3.421$, der durchschnittlichen Vorhersage des Modells.

Von diesem Wert ausgehend, illustrieren die Balken, wie jede Merkmalausprägung – angezeigt durch die grauen Zahlen entlang der y-Achse – die Vorhersage $f(x_j^{(0)})$ beeinflusst. So steigert beispielsweise blast mit einem Wert von 4.982 die Vorhersage um +0.21, wohingegen cement mit einem Wert von 5.035 die Vorhersage um -0.45 verringert.

Rote Balken repräsentieren Merkmale, die die Vorhersage erhöhen, während blaue Balken solche darstellen, die sie senken. Die Größe jedes Balkens zeigt das Ausmaß des jeweiligen Beitrags, und die abschließende Vorhersage $f(x) = 3.257$ wird am Ende der Kette dieser Effekte erreicht.

Kleine positive und negative Beiträge von Merkmalen wie fine (6.713), water (5.188), ash (0) und superplasticizer (2.197) zeigen, wie feingranulare Anpassungen der Merkmalsausprägungen die Vorhersage leicht erhöhen oder senken können.

Für die Beobachtung $x^{(0)}$ führt die kumulative Abweichung der Merkmal-Effekte vom Basiswert $\mathbb{E}[f(X)] = 3.421$ zu einem tatsächlichen Modelloutput von $f(x) = 3.257$,

was eine Differenz von -0.164 zwischen der durchschnittlichen Vorhersage und der spezifischen Vorhersage für diese Beobachtung offenlegt. Diese Differenz entspricht der Summe aller SHAP-Werte für diese konkrete Beobachtung [Mol23, S. 52f].

Da die Zielgröße einer logarithmischen Transformation unterzogen wurde, muss diese für die Interpretation wieder rückgängig gemacht werden. Dies bedeutet, dass der tatsächliche erwartete Wert der Druckfestigkeit der Exponentialfunktion des prognostizierten Wertes entspricht, also $e^{3.421} \approx 30.60$ MPa. Dieser Rücktransformationsprozess ist notwendig, um die Modellprognosen in der ursprünglichen Skala der Zielvariablen zu interpretieren. Dies gilt darüberhinaus sowohl für die einzelnen SHAP-Werte, als auch für die konkrete Vorhersage $f(x) = 3.257$. Die prognostizierte Druckfestigkeit für die Beobachtung $x^{(0)}$ beträgt folglich $e^{3.257} \approx 25.97$ MPa.

Dies ermöglicht eine detaillierte Analyse, wie das Modell zu einer bestimmten Vorhersage kommt, und hilft dabei, die Beiträge und Interaktionen zwischen verschiedenen Merkmalen zu verstehen.

Die lokale Interpretation mittels SHAP-Werten ermöglicht zwar eine präzise Erklärung der Modellvorhersagen für individuelle Beobachtungen, jedoch stellt sich bei einer solchen Betrachtung das Problem der fehlenden Generalisierbarkeit. Lokale Analysen können dazu führen, dass spezifische Merkmal-Kontributionen überinterpretiert werden, ohne die übergeordneten Muster und Einflüsse zu berücksichtigen, die das Modellverhalten im gesamten Datensatz charakterisieren. Eine globale Interpretation ist daher erforderlich, um die Konsistenz und Zuverlässigkeit des Modells über verschiedene Beobachtungen hinweg zu erfassen.


7.3.2. Globale Interpretation

Der folgende Abschnitt widmet sich dieser globalen Sichtweise und untersucht, wie die Merkmalsbeiträge sich im Kontext des gesamten Datensatzes darstellen lassen.

Der SHAP Beeswarm Plot in Abbildung 12 bietet eine globale Sicht auf die Modellvorhersagen, indem er die Verteilung der SHAP-Werte für jedes Merkmal über alle Beobachtungen hinweg darstellt. Jeder Punkt repräsentiert eine Beobachtung aus dem Datensatz. Die Farbe der Punkte zeigt die Merkmalsausprägungen an: hohe Werte in Rot und niedrige Werte in Blau. Die Position auf der x-Achse gibt den Einfluss des Merkmals auf die Modellvorhersage an. Positive SHAP-Werte (rechts von der Nulllinie) zeigen eine Erhöhung der Vorhersage an, während negative Werte (links von der Nulllinie) eine Verringerung bedeuten.

Das Merkmal `age` zeigt eine hohe Variabilität in seinem Einfluss auf die Modellvorhersage. Höhere Werte von `age` sind mit einer Zunahme der Vorhersage (positive SHAP-Werte) assoziiert, was durch die rechtsseitigen Punkte in der Grafik dargestellt wird. Niedrigere Werte führen hingegen zu einer geringeren Vorhersage, erkennbar an den linksseitigen Punkten. Diese Streuung der Punkte zeigt, dass die Auswirkung

Abbildung 12.: SHAP Beeswarm Plot.




Quelle: Eigene Darstellung, A.3.

von age auf die Vorhersage stark von seiner quantitativen Ausprägung abhängt.

Diese Darstellung ermöglicht es, die Merkmale zu identifizieren, die den größten Einfluss auf das Modell haben und wie dieser Einfluss über unterschiedliche Beobachtungen variiert.

Abbildung 13.: SHAP Bar Plot.



Quelle: Eigene Darstellung, A.3.

Der SHAP Bar Plot in Abbildung 13 illustriert die durchschnittliche Auswirkung jedes Merkmals auf das Modell, gemessen an der absoluten Größe der SHAP-Werte über alle Beobachtungen hinweg. Die Balken zeigen die durchschnittlichen Beiträge der Merkmale zur Vorhersage: Je länger der Balken, desto größer ist der Einfluss des jeweiligen Merkmals. Hier ist das Merkmal `age` mit dem höchsten durchschnittlichen SHAP-Wert ($+0.27$) das einflussreichste Merkmal, was auf eine starke positive Beziehung zur Zielvariablen hinweist. Die weiteren Merkmale folgen in absteigender Reihenfolge ihrer Bedeutung.

Es fällt auf, dass eine Übereinstimmung in der Reihenfolge der Merkmalsrelevanz zwischen der Permutation Feature Importance aus Abbildung 9 und den SHAP-Werten aus Abbildung 13 besteht, obwohl die zugrundeliegenden Interpretationen dieser beiden Methoden deutlich verschieden sind.

Die Permutation Feature Importance konzentriert sich darauf, die Veränderungen im Vorhersagefehler des Modells, speziell den mittleren quadratischen Fehler, zu messen, die eintreten, wenn die Werte eines Merkmals zufällig vertauscht werden. Diese Methode gibt Aufschluss darüber, wie stark das Modell auf das jeweilige Merkmal für seine Vorhersagegenauigkeit angewiesen ist. Ein wesentliches Merkmal dieser Methode ist, dass sie nicht direkt die Wechselwirkungen zwischen den Merkmalen berücksichtigt. Sie zeigt vielmehr, wie wichtig ein Merkmal isoliert für die Gesamtleistung des Modells ist.

Im Gegensatz dazu bieten die SHAP-Werte einen tieferen Einblick in die Beiträge jedes Merkmals zur Vorhersageleistung des Modells. Sie quantifizieren den Einfluss eines Merkmals auf die Abweichung der Prognose vom Basiswert, also der durchschnittlichen Vorhersage des Modells. Hierbei wird nicht nur die individuelle Wichtigkeit jedes Merkmals hervorgehoben, sondern auch deren Wechselwirkungen mit anderen Merkmalen berücksichtigt. Diese Methodik ermöglicht es, sowohl eine globale als auch eine lokale Perspektive auf die Modellvorhersagen zu werfen. Während die globale Interpretation durchschnittliche Auswirkungen aller Merkmale aufzeigt, erlaubt die lokale Sichtweise, die Vorhersagen für einzelne Beobachtungen präzise zu erklären.

Diese unterschiedlichen Herangehensweisen und Interpretationen der Merkmalsrelevanz, einerseits durch die Permutation Feature Importance und andererseits durch die SHAP-Werte, verdeutlichen die Komplexität und die Tiefe der Analyse, die für ein umfassendes Verständnis von Vorhersagemodellen erforderlich ist. Beide Methoden ergänzen sich gegenseitig und tragen dazu bei, ein vollständigeres Bild der Dynamiken innerhalb des Modells zu zeichnen.

Shapley-Werte bieten für die Prognose der Druckfestigkeit von Beton einen signifikanten Vorteil, da sie eine gerechte Verteilung des Vorhersagebeitrags über alle Merkmale gewährleisten. Diese gerechte Verteilung ist eine der Kernstärken der Shapley-Werte, die sie von anderen Methoden abhebt.

Die Druckfestigkeit von Beton ist das Ergebnis einer komplexen Interaktion verschiedener Materialkomponenten und Eigenschaften wie Zementgehalt, Wasser-Zement-Verhältnis, Zuschlagstoffe und Alter des Betons. Jede dieser Komponenten trägt unterschiedlich zur Endfestigkeit bei, und ihre Effekte können nicht isoliert betrachtet werden, da sie interdependent sind. Hier ermöglichen Shapley-Werte eine faire und ausgewogene Zurechnung der Einflüsse jedes Merkmals auf die Vorhersage, indem sie die marginalen Beiträge jedes Merkmals unter Berücksichtigung aller möglichen Kombinationen von Merkmalen im Modell kalkulieren.

Andere Methoden, wie beispielsweise die Betrachtung von Regressionskoeffizienten, geben zwar Aufschluss über die Richtung und Stärke des Zusammenhangs zwischen Merkmalen und der Zielvariable, vernachlässigen jedoch die Interaktionseffekte zwischen den Merkmalen.

In der Praxis bedeutet dies für die Prognose der Druckfestigkeit von Beton, dass Shapley-Werte eine präzise Zuordnung der Einflussstärke jedes Bestandteils und Verarbeitungsmerkmals erlauben. Da die Festigkeit von Beton von einer Vielzahl von Faktoren abhängt, ermöglicht die granulare Aufschlüsselung der Shapley-Werte eine detailreiche Einsicht, welche Komponenten optimiert werden sollten, um die gewünschten Eigenschaften des Betons zu erreichen.

Im Kontext von industriellen Anwendungen und Forschung, wo Entscheidungen auf Grundlage der Modellvorhersagen getroffen werden, gewährleisten Shapley-Werte somit eine transparente und gerechtfertigte Grundlage. Dies ist nicht nur für die Entwicklung von Betonmischungen von Bedeutung, sondern auch für die Einhaltung von Bauvorschriften und die Gewährleistung der Sicherheit. Durch die Verwendung von Shapley-Werten kann die Forschung im Bereich der Materialwissenschaften fundierter und zielgerichteter gestaltet werden, was zu einer effizienteren und effektiveren Materialentwicklung führt.

Im abschließenden Kapitel dieser Arbeit werden die wichtigsten Erkenntnisse zusammengefasst und diskutiert.

8. Fazit

Diese Arbeit hat die Anwendung und Interpretation von SHAP-Werten in der linearen Regressionsanalyse zur Vorhersage der Druckfestigkeit von Beton umfassend untersucht. SHAP-Werte, als ein fortschrittlicher Ansatz zur Modellinterpretation, haben sich als besonders wertvoll erwiesen, indem sie eine tiefere und nuanciertere Einsicht in die Beiträge einzelner Merkmale zur Modellvorhersage bieten. Im Vergleich zu herkömmlichen Interpretationsmethoden, wie der Analyse der Regressionskoeffizienten und der Permutation Feature Importance, bieten SHAP-Werte mehrere entscheidende Vorteile.

Einer der Hauptvorteile von SHAP-Werten liegt in ihrer Fähigkeit, sowohl globale als auch lokale Interpretationen zu ermöglichen. Sie erlauben es, den Einfluss einzelner Merkmale auf spezifische Vorhersagen zu verstehen, während gleichzeitig ein Überblick über deren Bedeutung im gesamten Modell gegeben wird. Darüber hinaus berücksichtigen SHAP-Werte die Interaktionen zwischen den Merkmalen und bieten somit eine ganzheitlichere Sicht auf die Modellvorhersagen. Dies ist besonders relevant in komplexen Datenstrukturen, wo Merkmalsinteraktionen eine signifikante Rolle spielen.

Ein weiterer zentraler Vorteil der SHAP-Werte liegt in ihrer umfassenden Erklärungskraft. Im Gegensatz zur Permutation Feature Importance, die sich darauf konzentriert, wie sich der Vorhersagefehler des Modells verändert, wenn die Werte eines Merkmals zufällig vertauscht werden, bieten SHAP-Werte eine detaillierte Aufschlüsselung des Beitrags jedes einzelnen Merkmals zur Vorhersage. Diese Eigenschaft der SHAP-Werte ist besonders wertvoll, da sie eine faire Aufteilung der Vorhersageabweichung unter allen Merkmalsausprägungen gewährleistet – bekannt als die Effizienzeigenschaft der Shapley-Werte. Diese faire Aufteilung ist besonders wichtig in Kontexten, in denen eine vollständige Erklärbarkeit erforderlich ist.

Trotz dieser Stärken ist es wichtig, auch die Grenzen der SHAP-Methode zu erkennen. Eine der Herausforderungen bei der Anwendung von SHAP-Werten ist die Interpretation der Ergebnisse, insbesondere wenn es um komplexe Modelle mit einer großen Anzahl von Merkmalen und komplizierten Interaktionen geht. Die Interpretation kann schnell überwältigend werden und erfordert ein tiefes Verständnis der zugrundeliegenden Daten und des Modells. Darüber hinaus kann die Berechnung von SHAP-Werten insbesondere bei großen Datensätzen rechenintensiv sein, was praktische Einschränkungen mit sich bringt [Mol22, S. 224].

Ein weiterer wichtiger Punkt ist die potenzielle Verzerrung, die durch die Stichpro-

benabhängigkeit der SHAP-Werte entstehen kann. SHAP-Werte basieren auf der Annahme, dass die Daten, auf denen das Modell trainiert wurde, repräsentativ für die zugrunde liegende Population sind. Wenn diese Annahme nicht erfüllt ist, können die SHAP-Werte irreführende Interpretationen liefern.

Zusammenfassend lässt sich sagen, dass SHAP-Werte eine bedeutende Erweiterung der Möglichkeiten zur Interpretation von linearen Modellen darstellen. Sie bieten tiefergehende Einblicke in die Funktionsweise von linearen Modellen und ermöglichen eine präzisere und umfassendere Analyse der Merkmalsrelevanz und -interaktionen. Dennoch ist es entscheidend, ihre Limitationen zu verstehen und sie als einen Teil eines umfassenden Prozesses der Modellinterpretation und -validierung zu betrachten.

Literaturverzeichnis

- [AFSS19] Encarnación Algaba, Vito Fragnelli, and Joaquín Sánchez-Soriano. Handbook of the shapley value. 2019. URL: <https://api.semanticscholar.org/CorpusID:213768429>.
- [LL17] Scott M Lundberg and Su-In Lee. A unified approach to interpreting model predictions. In I. Guyon, U. Von Luxburg, S. Bengio, H. Wallach, R. Fergus, S. Vishwanathan, and R. Garnett, editors, *Advances in Neural Information Processing Systems*, volume 30. Curran Associates, Inc., 2017. URL: https://proceedings.neurips.cc/paper_files/paper/2017/file/8a20a8621978632d76c43dfd28b67767-Paper.pdf.
- [Mol22] Christoph Molnar. *Interpretable machine learning: A guide for making Black Box models explainable*. Chistoph Molnar c/o Mucbook Clubhouse, Heidi Seibold, 2 edition, 2022.
- [Mol23] Christoph Molnar. *Interpreting machine learning models with SAP A guide with python examples and theory on Shapley Values*. Chistoph Molnar c/o MUCBOOK, 1 edition, 2023.
- [RC04] Christian P. Robert and George Casella. *Monte Carlo Statistical Methods*. Springer, 2004. URL: https://mcube.lab.nycu.edu.tw/~cfung/docs/books/robert2004monte_carlo_statistical_methods.pdf.
- [RWB⁺22] Benedek Rozemberczki, Lauren Watson, Péter Bayer, Hao-Tsung Yang, Olivér Kiss, Sebastian Nilsson, and Rik Sarkar. The shapley value in machine learning. In Lud De Raedt, editor, *Proceedings of the Thirty-First International Joint Conference on Artificial Intelligence, IJCAI-22*, pages 5572–5579. International Joint Conferences on Artificial Intelligence Organization, 7 2022. Survey Track. doi:10.24963/ijcai.2022/778.
- [Sha53] L. S. Shapley. 17. A Value for n -Person Games, pages 307–318. Princeton University Press, Princeton, 1953. URL: <https://doi.org/10.1515/9781400881970-018>, doi:doi:10.1515/9781400881970-018.
- [Yeh07] I-Cheng Yeh. Concrete Compressive Strength. UCI Machine Learning Repository, 2007. DOI: <https://doi.org/10.24432/C5PK67>.

Abbildungsverzeichnis

Abbildung 1: Beitrag der Merkmale $x_{j \in \{1,2,3\}}$ zur Modellvorhersage $f(x^{(1)})$. . .	15
Abbildung 2: Beitrag der Merkmale $x_{j \in \{1,2,3\}}$ zur Modellvorhersage $f(x^{(2)})$. . .	16
Abbildung 3: Boxplot der Merkmale vor und nach der Log-Transformation. . .	28
Abbildung 4: Verteilungen der Merkmale.	28
Abbildung 5: Korrelationsmatrix der Merkmale im Datensatz.	29
Abbildung 6: Residuenanalyse: Beziehung zwischen Vorhersagen und Abweichungen.	34
Abbildung 7: Koeffizienten des linearen Regressionsmodells.	35
Abbildung 8: Effektplot für Beobachtung $x^{(0)}$ der Testmenge.	36
Abbildung 9: Permutation Feature Importance.	37
Abbildung 10: SHAP Partial Dependence Plot für Beobachtung $x^{(0)}$ der Testmenge.	38
Abbildung 11: SHAP Waterfall Plot für Beobachtung $x^{(0)}$ der Testmenge. . . .	39
Abbildung 12: SHAP Beeswarm Plot.	41
Abbildung 13: SHAP Bar Plot.	41

Tabellenverzeichnis

Tabelle 1: Potenzielle Gewinne für verschiedene Teilnehmerkonstellationen im Designwettbewerb.	5
Tabelle 2: Marginalbeiträge der einzelnen Teilnehmer zu den möglichen Koalitionen.	5
Tabelle 3: Terminologie der originären Shapley-Werte im Kontext des maschinellen Lernens.	10
Tabelle 4: Merkmale von Beobachtungen in einem Immobilien-Datensatz. . . .	12
Tabelle 5: Marginalbeiträge der einzelnen Merkmale zu den möglichen Koalitionen für die Beobachtung $x^{(1)}$	14
Tabelle 6: Marginalbeiträge der einzelnen Merkmale zu den möglichen Koalitionen für die Beobachtung $x^{(2)}$	15
Tabelle 7: Auszug aus dem Concrete Compressive Strength Datensatz.	27
Tabelle 8: Statistische Übersicht des Concrete Compressive Strength Datensatzes.	27
Tabelle 9: Koeffizienten des linearen Regressionsmodells.	33
Tabelle 10: Modellmetriken des linearen Regressionsmodells.	34

Quellcodeverzeichnis

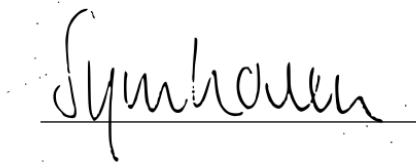
Codeauschnitt 6.1: Initialisierung eines linearen Regressionsmodells, A.3.	30
Codeauschnitt 6.2: Training und Testen eines linearen Regressionsmodells, A.3.	30
Codeauschnitt 6.3: Berechnung von SHAP-Werten für das lineare Regressionsmodell, A.3.	31
Codeauschnitt 6.4: Erzeugen der SHAP Plots, A.3.	31

Eidesstattliche Erklärung

Ich versichere an Eides statt, dass ich die vorstehende Arbeit selbständig und ohne fremde Hilfe angefertigt und mich anderer als der im beigefügten Verzeichnis angegebenen Hilfsmittel nicht bedient habe. Alle Stellen, die wörtlich oder sinngemäß aus Veröffentlichungen übernommen wurden, sind als solche kenntlich gemacht. Alle Internetquellen sind der Arbeit beigefügt.

Des Weiteren versichere ich, dass ich die Arbeit vorher nicht in einem anderen Prüfungsverfahren eingereicht habe und dass die eingereichte schriftliche Fassung der auf dem elektronischen Speichermedium entspricht.

München, 15. Januar 2024

A handwritten signature in black ink, reading 'Symhoven', written over a horizontal line.

SIMON SYMHOVEN

A. Quellcode

A.1. requirements.txt

```
1 pandas
2 matplotlib
3 scikit-learn
4 numpy
5 shap
6 seaborn
7 statsmodels
8 mlxtend
9 requests
10 xlrd
```

A.2. charts.py

```
1 import matplotlib.pyplot as plt
2 from typing import List
3
4 plt.rcParams.update({
5     'text.usetex': True,
6     'text.latex.preamble': r'\usepackage{amsfonts}'
7 })
8
9 def plot_waterfall(expected_value_model: float, observation_values: List[float],
10                   observation_labels: List[str], contributions: List[float],
11                   name: str, index: int):
12     """
13     Creates a waterfall chart plot that visualizes the expected model value,
14     observation values, their contributions, and labels.
15
16     Parameters:
17     - expected_value_model (float): The expected model value.
18     - observation_values (List[float]): A list of observation values.
19     - observation_labels (List[str]): A list of labels associated with
20       the observation values.
21     - contributions (List[float]): A list of contributions representing
22       changes from observation values to the
23       model value.
24     - name (str): The name of the plot and the file for saving.
25     - index (int): The index for the observation.
26     """
27
28     labels = [f'{value} = {label}' for (value, label)
29               in zip(observation_values, observation_labels)]
30     waterfall = [expected_value_model]
31     for contribution in contributions:
32         waterfall.append(waterfall[-1] + contribution)
33
34     _, ax = plt.subplots(figsize=(10, 3))
35
36     for idx, (contribution, start) in enumerate(
```

```

37         zip(contributions, waterfall[:-1])
38     ):
39         ax.barh(idx, contribution, left=start, color='blue'
40                 if contribution >= 0 else 'red', height=0.5, alpha=0.8)
41         text_x = start + contribution / 2
42         ax.text(text_x, idx, contribution, va='center', ha='center', fontsize=12,
43                 color='white')
44
45     l1 = r'$\mathbb{E}(f(X)) = $' + f' {expected_value_model} Euro'
46     l2 = r'$f(x^{\{{{index}}}}) = {waterfall_value} Euro'.format(index=index,
47                             waterfall_value=waterfall[-1])
48     ax.text(expected_value_model, -1.2, l1, va='center', ha='center')
49     ax.text(waterfall[-1], 2.8, l2, va='center', ha='center')
50
51     ax.set_yticks(range(len(labels)))
52     ax.set_yticklabels(labels)
53     ax.set_xlabel('Euro')
54
55     ax.axvline(x=expected_value_model, color='grey', linestyle='--', linewidth=1)
56     ax.axvline(x=waterfall[-1], color='grey', linestyle='--', linewidth=1)
57
58     ax.set_xlim(min(waterfall)-5, max(waterfall)+5)
59
60     for spine in ['top', 'right', 'left']:
61         ax.spines[spine].set_visible(False)
62
63     plt.tight_layout()
64     plt.tick_params(left = False)
65     plt.savefig(f'images/{name}', dpi=300)
66
67 """
68 Create charts for observation  $x^{\{1\}}$  and  $x^{\{2\}}$ 
69 """
70 # General Model Values
71 observation_labels = ['Groesse', 'Anzahl Zimmer', 'Entfernung zum Zentrum']
72 expected_value_model = 680
73
74 # Observation values and contributions for  $x^{\{1\}}$ 
75 index = 1
76 observation_values_x1 = [100, 3, 5]
77 contributions_x1 = [-125, -10, 5]
78
79 plot_waterfall(expected_value_model=expected_value_model,
80                 observation_values=observation_values_x1,
81                 observation_labels=observation_labels,
82                 contributions=contributions_x1,
83                 name="model-output-x1.png", index=index)
84
85 # Observation values and contributions for  $x^{\{2\}}$ 
86 index = 2
87 observation_values_x2 = [150, 4, 10]
88 contributions_x2 = [125, 10, -5]
89
90 plot_waterfall(expected_value_model=expected_value_model,
91                 observation_values=observation_values_x2,
92                 observation_labels=observation_labels,
93                 contributions=contributions_x2,
94                 name="model-output-x2.png", index=index)

```

A.3. linreg.py


```
1 import requests
2 import zipfile
3 from io import BytesIO
4 import pandas as pd
5 from sklearn.model_selection import train_test_split
6 import matplotlib.pyplot as plt
7 import matplotlib
8 import seaborn as sns
9 import shap
10 from sklearn.linear_model import LinearRegression
11 from sklearn.metrics import mean_absolute_error, mean_squared_error
12 import numpy as np
13 from sklearn.inspection import permutation_importance
14
15 matplotlib.use('Agg')
16
17 def load_data() -> pd.DataFrame:
18     """
19     Loads and returns the dataset from the given URL as a Pandas DataFrame.
20
21     Returns:
22         pd.DataFrame: The loaded dataset.
23     """
24     url = "https://archive.ics.uci.edu/static/public/165/concrete+compressive+strength.zip"
25
26     r = requests.get(url)
27
28     if r.ok:
29         with zipfile.ZipFile(BytesIO(r.content)) as thezip:
30             with thezip.open("Concrete_Data.xls") as thefile:
31                 return pd.read_excel(thefile, header=0)
32     else:
33         raise Exception("Something went wrong.")
34
35 def model(X: pd.DataFrame, y: pd.Series) -> (LinearRegression, pd.DataFrame):
36     """
37     Fits a Linear Regression model to the given data.
38
39     Args:
40         X (pd.DataFrame): The feature matrix.
41         y (pd.Series): The target variable.
42
43     Returns:
44         LinearRegression: The fitted Linear Regression model.
45         DataFrame: The coefficients as DataFrame.
46     """
47     model = LinearRegression()
48     model.fit(X, y)
49
50     cdf = pd.DataFrame(model.coef_.round(5), X.columns, columns=['Coefficients'])
51     cdf.loc['Intercept'] = model.intercept_.round(5)
52
53     return model, cdf
54
55 def plot_residuals(y_test: pd.Series, y_pred: pd.Series) -> None:
56     """
57     Creates and saves residual plots.
58
59     Args:
60         y_test (pd.Series): The actual target values.
```



```

120         feature_expected_value=True,
121         ice=False,
122         shap_values=shap_values[idx:idx+1,:])
123     plt.tight_layout()
124     plt.savefig('images/shap_dependence_plot.png', dpi=300)
125
126 def plot_dist(df: pd.DataFrame) -> None:
127     """
128     Creates and saves distribution and histogram plot over all
129     features of df.
130
131     Args:
132         df (pd.DataFrame): The feature matrix.
133     """
134     _, axes = plt.subplots(3, 3, figsize=(15, 10))
135     axes = axes.flatten()
136
137     for i, var in enumerate(df.columns):
138         sns.histplot(df[var], ax=axes[i], kde=True)
139         axes[i].set_title(var)
140
141     plt.tight_layout()
142     plt.savefig('images/dist.png', dpi=300)
143     plt.show()
144
145 def plot_coef(coef: pd.DataFrame) -> None:
146     """
147     Plot the coefficients of a linear model as a horizontal bar chart.
148
149     Args:
150         coef (pd.DataFrame): A DataFrame containing the model's coefficients,
151                             with feature names as the index and a 'Coefficients'
152                             column.
153     """
154     coef = coef.drop('Intercept', errors='ignore')
155     coef = coef.sort_values(by='Coefficients', ascending=True)
156     plt.figure(figsize=(12, 10))
157     plt.barh(coef.index, coef['Coefficients'])
158     plt.axvline(0)
159     plt.xlabel('Coefficients')
160     plt.ylabel('Features')
161     plt.savefig('images/coef.png', dpi=300)
162     plt.show()
163
164 def plot_box(df: pd.DataFrame, df2: pd.DataFrame) -> None:
165     """
166     Plot the distribution of two dataframes as a box plot.
167
168     Args:
169         df (pd.DataFrame): First dataframe.
170         df2 (pd.DataFrame): Second dataframe.
171     """
172     fig, axs = plt.subplots(1, 2, figsize=(12, 4))
173
174     axs[0].boxplot(df2.values, vert=False)
175     axs[0].set_title('original')
176     axs[0].set_yticklabels(df2.columns)
177
178     axs[1].boxplot(df.values, vert=False)
179     axs[1].set_title('log-transformed')
180     axs[1].set_yticklabels(df.columns)

```

```

180
181 plt.tight_layout()
182 plt.savefig('images/boxplot.png', dpi=300)
183 plt.show()
184
185 def plot_permutation_importance(perm_importance_train: permutation_importance,
186                                perm_importance_test: permutation_importance,
187                                columns: np.ndarray) -> None:
188     """
189     Plots the permutation importance of features for both training and test
190     datasets.
191
192     Args:
193         perm_importance_train (object): A fitted PermutationImportance instance
194         for the training dataset.
195         perm_importance_test (object): A fitted PermutationImportance instance for
196         the test dataset,
197         columns (list or array): An array or list of feature names corresponding
198         to the indices in
199         the perm_importance objects.
200
201     """
202     fig, axs = plt.subplots(1, 2, figsize=(12, 4))
203
204     sorted_idx_train = perm_importance_train.importances_mean.argsort()
205     axs[0].barh(range(len(sorted_idx_train)), perm_importance_train.
206                importances_mean[sorted_idx_train], align='center')
207     axs[0].set_title('train')
208     axs[0].set_xlabel('Change in MSE')
209     axs[0].set_yticks(range(len(sorted_idx_train)), np.array(columns)[
210                        sorted_idx_train])
211
212     sorted_idx_test = perm_importance_test.importances_mean.argsort()
213     axs[1].barh(range(len(sorted_idx_test)), perm_importance_test.importances_mean
214                [sorted_idx_test], align='center')
215     axs[1].set_title('test')
216     axs[1].set_xlabel('Change in MSE')
217     axs[1].set_yticks(range(len(sorted_idx_test)), np.array(columns)[
218                        sorted_idx_test])
219
220     plt.tight_layout()
221     plt.savefig('images/permutation_importance.png', dpi=300)
222     plt.show()
223
224 def plot_feature_effects(coef: pd.DataFrame, X: pd.DataFrame, idx: int) -> None:
225     """
226     Create and save a box plot of feature effects.
227
228     Args:
229         coef (pd.DataFrame): A DataFrame containing the model's coefficients,
230         with feature names as the index and a 'Coefficients'
231         column.
232         X (pd.DataFrame): The feature matrix.
233         idx (int): Index for the data point to plot.
234     """
235     coef = coef.drop('Intercept', errors='ignore')
236     feature_effects = X * coef['Coefficients']

```

```

230     feature_names = X.columns
231
232     plt.figure(figsize=(12, 6))
233     plt.boxplot(feature_effects.values, vert=False)
234     plt.plot(X.iloc[idx] * coef['Coefficients'], range(1, len(X.iloc[idx]) + 1), '
235             rx', markersize=10)
236     plt.axvline(0, linestyle='--', color='black')
237     plt.xlabel('Feature Effects')
238     plt.ylabel('Features')
239     plt.yticks(range(1, len(feature_names) + 1), feature_names)
240     plt.tight_layout()
241     plt.savefig('images/feature_effects_boxplot.png', dpi=300)
242     plt.show()
243
244 df = load_data()
245 df = df.rename(
246     columns={
247         'Cement (component 1)(kg in a m^3 mixture)': 'cement',
248         'Blast Furnace Slag (component 2)(kg in a m^3 mixture)': 'blast',
249         'Fly Ash (component 3)(kg in a m^3 mixture)': 'ash',
250         'Water (component 4)(kg in a m^3 mixture)': 'water',
251         'Superplasticizer (component 5)(kg in a m^3 mixture)': 'superplasticizer',
252         'Coarse Aggregate (component 6)(kg in a m^3 mixture)': 'coarse',
253         'Fine Aggregate (component 7)(kg in a m^3 mixture)': 'fine',
254         'Age (day)': 'age',
255         'Concrete compressive strength(MPa, megapascals) ': 'strength'
256     }
257 )
258 df = df.drop_duplicates()
259 df_original = df.copy()
260
261 print(df.head())
262 print(df.isnull().sum())
263 print(df.describe().T)
264
265 for column in df.columns:
266     df[column] += 1
267     df[column] = np.log(df[column])
268
269 plot_dist(df=df)
270 plot_box(df=df, df2=df_original)
271
272 X = df.drop(['strength'], axis=1)
273 y = df['strength']
274
275 X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.20,
276             random_state=42)
277
278 linreg, coef = model(X=X_train, y=y_train)
279 y_pred = linreg.predict(X_test)
280
281 perm_importance_train = permutation_importance(linreg, X_train, y_train)
282 perm_importance_test = permutation_importance(linreg, X_test, y_test)
283 plot_permutation_importance(perm_importance_train, perm_importance_test, X.columns
284 )
285
286 explainer = shap.Explainer(linreg, X_train)
287 shap_values = explainer(X_test)
288
289 mae = mean_absolute_error(y_test, y_pred)

```

```
288 mse = mean_squared_error(y_test, y_pred)
289 train_score = linreg.score(X_train, y_train)
290 test_score = linreg.score(X_test, y_test)
291
292 print(f"Mean Absolute Error (MAE): {mae:.2f}")
293 print(f"Mean Squared Error (MSE): {mse:.2f}")
294 print(f"Root Mean Squared Error (RMSE): {mse ** 0.5:.2f}")
295 print(f"Training Score (R^2): {train_score:.4f}")
296 print(f"Test Score (R^2): {test_score:.4f}")
297
298 plot_coef(coef=coef)
299 print(coef)
300 plot_corr(df=df)
301 plot_residuals(y_test=y_test, y_pred=y_pred)
302 plot_shap(shap_values=shap_values, model=linreg, X=X_test, idx=0)
303 plot_feature_effects(coef=coef, X=X_test, idx=0)
```